

ارزیابی مقاومت در برابر تغییر دامنه در تقطیع ریه در تصاویر
رادیوگرافی قفسه سینه

مقایسه **U-Net** آموزش دیده از صفر در برابر **SAM ViT-**
B با تنظیم دقیق کارآمد پارامتر

ارائه دهنده : محمد فواد ادیب

استاد : دکتر افشاری

درس : مبانی بینایی کامپیوتر

فهرست مطالب

چکیده

فصل اول: مقدمه

زمینه پژوهش

بیان دقیق مسئله

تمایز علمی

فصل دوم: اهداف و سوالات پژوهش

هدف کلی

اهداف جزئی

سوالات پژوهشی

فصل سوم: مرور ادبیات و استدلال روش‌شناختی

چرا BUSI و COVID-Radiography رد شدند

چرا Shenzhen و Montgomery انتخاب شدند

استدلال برای معماری تولید Prompt

استدلال برای انتخاب راهبرد Fine-Tuning

تصمیمات منفی

فصل چهارم: گزارش اجرای داده

منبع داده

پروتکل پاکسازی

استراتژی تقسیم

پیش پردازش تصویر

فصل پنجم: معماری نرم افزار

نقشه ماژول ها

ترتیب اجرا

معماری Attention U-Net

SAM Fine-Tuning

مدیریت حافظه

اشکالات شناسایی شده

فصل ششم: پروتکل آزمایشی

سخت افزار

پیکربندی U-Net

پیکربندی SAM Freeze

پیکربندی SAM LoRA

طرح Ablation A1-A8

فصل هفتم: نتایج

نتایج کمی اصلی

کارایی پارامتری

مصرف حافظه

نرخ Fallback

منحنی‌های آموزش

نمودار مقایسه‌ای

نقشه حرارتی شاخص‌ها

فصل هشتم: مطالعه Ablation

تحلیل A4 در برابر A7

تحلیل A3 در برابر A4

تحلیل A4 در برابر A6

تحلیل A4 در برابر A8

فصل نهم: بحث و تحلیل

پاسخ RQ1

پاسخ RQ2

پاسخ RQ3

پاسخ RQ4

پاسخ RQ5

فصل دهم: بررسی ریسک‌ها

فصل یازدهم: نتیجه‌گیری

فصل دوازدهم: کارهای آینده

فهرست منابع

تقطیع خودکار ریه در تصاویر رادیوگرافی قفسه سینه یکی از مراحل حیاتی در سیستم‌های تشخیص کمکی رایانه‌ای برای بیماری‌های تنفسی محسوب می‌شود. با وجود پیشرفت‌های چشمگیر در یادگیری عمیق برای تقطیع پزشکی، مسئله عمومی‌پذیری مدل‌ها در مواجهه با داده‌های از دامنه‌های مختلف — برای نمونه، تغییر در پروتکل تصویربرداری، تجهیزات رادیوگرافی، و ویژگی‌های دموگرافیک جمعیت — همچنان یک چالش بنیادین باقی مانده است. مدل‌های یادگیری عمیق معمولاً در یک دامنه خاص آموزش می‌بینند و عملکرد آن‌ها هنگام انتقال به دامنه‌ای جدید به‌طور قابل ملاحظه‌ای افت می‌کند. این پدیده که به عنوان تغییر دامنه (Domain Shift) شناخته می‌شود، مانع بزرگی بر سر راه استقرار بالینی این سیستم‌ها در محیط‌های واقعی است.

در سال‌های اخیر، مدل Segment Anything Model (SAM) که توسط متا (Meta) معرفی شده، به عنوان یک مدل پایه همه‌منظوره در حوزه بینایی ماشین شناخته می‌شود. SAM با بیش از ۹۰ میلیون پارامتر و معماری مبتنی بر Vision Transformer، قابلیت تقطیع در انواع تصاویر را بدون آموزش اختصاصی دارد. با این وجود، استفاده از SAM برای کارهای پزشکی نیازمند منابع محاسباتی قابل توجهی است و به‌ویژه در محیط‌هایی با محدودیت حافظه گرافیکی مانند کارت‌های T4 با ۱۴ گیگابایت حافظه، چالش‌های جدی ایجاد می‌کند. به همین دلیل، تکنیک‌های تنظیم دقیق کارآمد پارامتر (PEFT) نظیر Layer Freezing و (LoRA) Low-Rank Adaptation به عنوان راهکارهایی برای بهره‌گیری از قدرت SAM با مصرف حافظه کنترل‌شده مطرح شده‌اند.

در این پژوهش، مقاومت در برابر تغییر دامنه در تقطیع ریه با استفاده از دو رویکرد متفاوت بررسی شده است: نخست، یک معماری Attention U-Net که از صفر و فقط بر روی داده‌های رادیوگرافی قفسه سینه آموزش دیده است؛ و دوم، مدل SAM ViT-B که با استراتژی‌های مختلف PEFT شامل Freeze-based و LoRA-based تنظیم دقیق شده است. ارزیابی بر روی دو مجموعه داده عمومی رادیوگرافی قفسه سینه — مجموعه داده شهر مونتگومری (۱۳۸ تصویر) از آرشیو ملی کتابخانه پزشکی ایالات متحده و مجموعه داده شنژن (۶۶۲ تصویر) — انجام شده است. برای سنجش عمومی‌پذیری بین‌دامنه‌ای، مدل‌ها بر روی یک دامنه آموزش داده شده و بر روی دامنه دیگر ارزیابی شده‌اند.

طرح آزمایشی شامل ۸ پیکربندی Ablation (A1 تا A8) است که طیف وسیعی از شرایط از جمله U-Net استاندارد، SAM بدون تنظیم (Zero-Shot)، SAM با لایه‌های انجمادی و Prompt Ensemble، SAM با LoRA، و همچنین سناریوهای Oracle و Stress Test را پوشش می‌دهد. پنج سوال پژوهشی محوری حول محورهای مقایسه عملکرد درون‌دامنه‌ای و بین‌دامنه‌ای، بهره‌وری LoRA، تحلیل افت عملکرد، نقش Prompt Engineering، و محدودیت‌های حافظه تعریف شده‌اند. یافته‌های کلیدی نشان می‌دهند که U-Net با ضریب Dice درون‌دامنه‌ای ۰.۹۵۳۱ بهترین عملکرد کلی را در دامنه آموزش خود دارد، در حالی که SAM با Freeze و Ensemble (A4) با ضریب ۰.۹۱۴۲ بهترین گونه SAM است. تفاوت عملکرد LoRA نسبت به Freeze تنها حدود ۰.۸ درصد بوده و افزایش قابل توجهی در مصرف حافظه ایجاد می‌کند. همه مدل‌ها هنگام انتقال به دامنه جدید، افت ۸ تا ۱۰ درصدی در ضریب Dice نشان می‌دهند.

واژگان کلیدی: تقطیع ریه، تغییر دامنه، Segment Anything Model، تنظیم دقیق کارآمد پارامتر، LoRA، Layer Freezing، رادیوگرافی قفسه سینه، یادگیری عمیق، بینایی کامپیوتر پزشکی.

زمینه پژوهش ۱-۱

بیماری‌های تنفسی از جمله سل، پنومونی، و سرطان ریه از جمله مهم‌ترین عوامل مرگومیر در سراسر جهان هستند. بر اساس آمار سازمان بهداشت جهانی، 每年 بیش از ۱۰ میلیون نفر به سل مبتلا می‌شوند و بیماری‌های تنفسی مزمن مسئول حدود ۴ میلیون مرگ در سال هستند. تشخیص به‌موقع و دقیق این بیماری‌ها نقش حیاتی در بهبود نرخ بقای بیماران دارد. در این میان، رادیوگرافی قفسه سینه به عنوان متداول‌ترین و در دسترس‌ترین ابزار تصویربرداری تشخیصی، خط مقدم غربالگری بیماری‌های ریوی محسوب می‌شود. با این حال، تفسیر دقیق تصاویر رادیوگرافی نیازمند تخصص بالینی است و در مناطقی با کمبود متخصص رادیولوژی، خطای تشخیصی می‌تواند منجر به تأخیر در درمان و افزایش مرگومیر شود.

در دهه گذشته، یادگیری عمیق تحول بزرگی در حوزه بینایی کامپیوتر و به‌ویژه پردازش تصاویر پزشکی ایجاد کرده است. معماری‌های مبتنی بر شبکه‌های عصبی پیچشی (CNN) نظیر U-Net و نسخه‌های بهبودیافته آن، به‌طور گسترده‌ای برای تقطیع اندام‌ها و ساختارهای آناتومیک در تصاویر پزشکی به کار رفته‌اند. U-Net با معماری رمزگذار-رمزگشا و اتصالات مقطعی، قابلیت استخراج ویژگی‌های چندمقیاسی را دارد و در بسیاری از کارهای تقطیع پزشکی نتایج برتری نشان داده است. اضافه کردن مکانیزم Attention به این معماری، توانایی مدل در تمرکز بر نواحی مرتبط و فیلتر کردن اطلاعات مزاحم را افزایش داده و به بهبود دقت تقطیع در مرزهای پیچیده کمک کرده است.

با این وجود، شبکه‌های عصبی پیچشی سنتی محدودیت‌هایی اساسی دارند. این مدل‌ها معمولاً بر روی مجموعه داده‌های خاص آموزش می‌بینند و توانایی تعمیم به دامنه‌های جدید را به‌خوبی ندارند. علاوه بر این، طراحی معماری‌های تخصصی برای هر کاربرد پزشکی نیازمند تخصص مهندسی قابل توجه و منابع محاسباتی است. در پاسخ به این محدودیت‌ها، مفهوم مدل‌های پایه (Foundation Models) در بینایی ماشین ظهور کرده است. Segment Anything Model (SAM) که در سال ۲۰۲۳ توسط آزمایشگاه هوش مصنوعی متا معرفی شد، یک گام بزرگ در این جهت محسوب می‌شود. SAM با بیش از ۹۰ میلیون پارامتر در نسخه ViT-B، توانایی تقطیع هر شیئی در هر تصویری را بدون آموزش اختصاصی دارد و به عنوان یک مدل همه‌منظوره در حوزه تقطیع عمل می‌کند.

SAM از معماری Image Encoder مبتنی بر Vision Transformer، Prompt Encoder، و Mask Decoder تشکیل شده است. انکودر تصویر ویژگی‌های غنی و عمیق را از تصویر ورودی استخراج می‌کند، انکودر Prompt انواع مختلف ورودی‌های هدایتی (نقاط، جعبه‌ها، ماسک‌ها) را پردازش می‌کند، و دکودر ماسک با ترکیب این دو منبع اطلاعات، ماسک تقطیع نهایی را تولید می‌کند. این معماری انعطاف‌پذیر اجازه می‌دهد SAM با دریافت Prompt‌های مختلف، تقطیع‌های متنوعی از یک تصویر واحد تولید کند. با این حال، بزرگترین چالش در استفاده از SAM برای کارهای پزشکی، مصرف بالای حافظه گرافیکی و نیاز به منابع محاسباتی قابل توجه است که استفاده از آن را در محیط‌هایی با سخت‌افزار محدود دشوار می‌سازد.

۱-۲ بیان دقیق مسئله

مسئله اصلی این پژوهش را می‌توان به صورت زیر formulate کرد: آیا مدل SAM ViT-B با استفاده از تکنیک‌های تنظیم دقیق کارآمد پارامتر (PEFT) می‌تواند به عملکردی comparable با یک معماری تخصصی U-Attention Net در تقطیع ریه در تصاویر رادیوگرافی قفسه سینه دست یابد، و همزمان مقاومت بهتری در برابر تغییر دامنه نشان دهد؟ این سوال از اهمیت ویژه‌ای برخوردار است زیرا SAM به عنوان یک مدل پایه با دانش از پیش آموزش‌دیده بر روی میلیون‌ها تصویر، پتانسیل نظری بهتری برای عمومی‌پذیری دارد.

چالش اساسی این پژوهش در محدودیت‌های سخت‌افزاری نهفته است. با در نظر گرفتن یک کارت گرافیکی NVIDIA T4 با ۱۴ گیگابایت حافظه ویدیویی، امکان تنظیم دقیق کامل SAM (Full Fine-Tuning) وجود ندارد. بنابراین، تنها گزینه‌های موجود استفاده از تکنیک‌های PEFT مانند Layer Freezing (انجماد بخش‌هایی از مدل و آموزش فقط لایه‌های جدید) و Low-Rank Adaptation (اضافه کردن ماتریس‌های رتبه‌کم به لایه‌های Attention)

هستند. هر یک از این رویکردها تعاملات متفاوتی با حافظه، سرعت آموزش، و کیفیت تقطیع دارند که نیاز به بررسی دقیق و مقایسه‌ای دارند.

علاوه بر این، مسئله Prompt Engineering برای SAM در حوزه پزشکی به‌خوبی حل نشده است. بر خلاف تصاویر طبیعی که در آن‌ها کاربر می‌تواند به‌صورت تعاملی نقاط یا جعبه‌هایی روی شیء مورد نظر قرار دهد، در یک سیستم خودکار تقطیع ریه، Prompt‌ها باید به‌صورت الگوریتمی و خودکار از خود تصویر تولید شوند. کیفیت این Prompt‌های خودکار تأثیر مستقیمی بر عملکرد SAM دارد و یک خطای کوچک در تولید Prompt می‌تواند به تقطیع نادرست منجر شود. این مسئله به‌ویژه در تصاویر رادیوگرافی که کنتراست پایین و ساختارهای آناتومیک همپوشان دارند، چالش‌برانگیزتر است.

بنابراین، این پژوهش به دنبال پاسخ به این سوال است که آیا با محدودیت ۱۴ گیگابایت حافظه گرافیکی، می‌توان SAM را به گونه‌ای تنظیم کرد که هم از نظر کمی به U-Net نزدیک شود و هم مزیت مقاومت در برابر تغییر دامنه را حفظ کند؟ و اگر پاسخ مثبت است، کدام راهبرد (Freeze یا LoRA) و کدام رویکرد تولید Prompt (جعبه واحد یا Ensemble) بهینه‌ترین نتیجه را فراهم می‌آورند؟

۱-۳ تمایز علمی

آنچه این پژوهش را از کارهای قبلی متمایز می‌کند، تمرکز صریح بر مسئله تغییر دامنه (Cross-Domain Robustness) به‌جای صرفاً دستیابی به بالاترین ضریب Dice درون‌دامنه‌ای است. بسیاری از مقالات موجود در ادبیات، مدل‌ها را فقط بر روی یک مجموعه داده آموزش داده و بر روی همان مجموعه ارزیابی کرده‌اند. این رویکرد، توانایی مدل در مواجهه با داده‌های واقعی از مراکز مختلف، تجهیزات متنوع، و جمعیت‌های دموگرافیک گوناگون را نمی‌سنجد. در عمل، وقتی یک مدل تقطیع ریه که بر روی تصاویر یک بیمارستان آموزش دیده در بیمارستان دیگری با تجهیزات متفاوت مستقر می‌شود، افت عملکرد قابل ملاحظه‌ای را تجربه می‌کند.

تمایز دوم این پژوهش، در نظر گرفتن محدودیت‌های واقعی حافظه گرافیکی است. بسیاری از مقالات SAM-based بدون توجه به محدودیت‌های سخت‌افزاری، از نسخه ViT-H (بیش از ۲ گیگابایت پارامتر) با Fine-Tuning کامل استفاده می‌کنند. در این پژوهش، صراحتاً محدودیت ۱۴ گیگابایتی T4 به عنوان یک constraint تعریف شده و تمام تصمیمات معماری، از انتخاب نسخه ViT-B تا استراتژی‌های مدیریت حافظه مانند Gradient Checkpointing و AMP، بر اساس این محدودیت گرفته شده‌اند. این رویکرد، نتایج پژوهش را برای محیط‌های عملیاتی واقعی‌تر و قابل اجرا تر می‌کند.

تمایز سوم، بررسی جامع و ساختاریافته ۸ پیکربندی مختلف در قالب یک طرح Ablation منسجم است. این طرح شامل U-Net استاندارد (A1)، SAM Zero-Shot (A2)، SAM با Freeze و Prompt واحد (A3)، SAM با Freeze و Prompt Ensemble (A4)، SAM با LoRA و Prompt واحد (A5)، SAM با LoRA و Prompt Ensemble (A6)، سناریوی Oracle با Prompt ایده‌آل (A7)، و Stress Test با Prompt تخریب‌شده (A8) است. این طیف گسترده امکان تحلیل دقیق هر عامل (نوع مدل، راهبرد PEFT، کیفیت Prompt) را فراهم می‌آورد و درک عمیق‌تری از عوامل مؤثر بر عملکرد تقطیع فراهم می‌کند.

فصل دوم: اهداف و سوالات پژوهش

۲-۱ هدف کلی

هدف کلی این پژوهش، ارزیابی جامع و ساختاریافته مقاومت در برابر تغییر دامنه در تقطیع ریه با استفاده از دو رویکرد متفاوت — یک معماری تخصصی Attention U-Net و مدل پایه SAM ViT-B با تکنیک‌های تنظیم دقیق کارآمد پارامتر — در تصاویر رادیوگرافی قفسه سینه است. این ارزیابی با در نظر گرفتن محدودیت‌های واقعی سخت‌افزاری (کارت گرافیکی T4 با ۱۴ گیگابایت حافظه) انجام می‌شود و هدف آن تعیین اینکه آیا رویکردهای مبتنی بر SAM می‌توانند مزیت مقاومت بین‌دامنه‌ای قابل توجهی نسبت به مدل‌های تخصصی ارائه دهند، به طوری که این مزیت هزینه اضافی حافظه و پیچیدگی آموزش را توجیه کند. نتیجه این پژوهش می‌تواند به محققان و توسعه‌دهندگان سیستم‌های تشخیص کمکی در تصمیم‌گیری بین استفاده از مدل‌های تخصصی سبک و مدل‌های پایه سنگین کمک کند.

۲-۲ اهداف جزئی

هدف جزئی اول: پیاده‌سازی و آموزش یک معماری Attention U-Net با ۴ سطح رمزگذار-رمزگشا و کانال‌های [۳۲، ۶۴، ۱۲۸، ۲۵۶] به عنوان خط پایه تخصصی برای تقطیع ریه، و ارزیابی عملکرد آن با اعتبارسنجی متقاطع ۵-تایی بر روی مجموعه داده آموزش. این مدل با حدود ۳.۴ میلیون پارامتر، نماینده‌ای از رویکردهای کلاسیک تقطیع پزشکی است و عملکرد آن به عنوان مرجع اصلی برای مقایسه با SAM استفاده می‌شود.

هدف جزئی دوم: پیاده‌سازی خط لوله تولید Prompt خودکار برای SAM شامل تشخیص خودکار کانتر ریه با استفاده از تکنیک‌های پردازش تصویر، استخراج جعبه محاطی و نقاط مرزی، و ایجاد تنوع در Prompt از طریق اعمال نویز و تغییر مقیاس. این خط لوله باید بتواند بدون دخالت انسانی، Prompt‌های باکیفیت برای SAM تولید کند و قابلیت تولید نسخه‌های Ensemble از Prompt‌ها را داشته باشد.

هدف جزئی سوم: پیاده‌سازی و مقایسه دو راهبرد تنظیم دقیق کارآمد پارامتر برای SAM شامل Freeze-based (انجماد انکودر تصویر و آموزش فقط دکودر ماسک) و LoRA-based (اضافه کردن ماتریس‌های رتبه‌کم به بلوک‌های Attention). هر دو راهبرد باید در محدودیت ۱۴ گیگابایت حافظه قابل اجرا باشند و مصرف حافظه آن‌ها دقیقاً اندازه‌گیری و گزارش شود.

هدف جزئی چهارم: طراحی و اجرای طرح آزمایشی Ablation با ۸ پیکربندی (A1 تا A8) برای تفکیک اثر هر عامل شامل نوع مدل (U-Net در برابر SAM)، راهبرد PEFT (Freeze در برابر LoRA در برابر Zero-Shot)، و کیفیت Prompt (واحد در برابر Ensemble در برابر Oracle در برابر Stress) بر عملکرد تقطیع درون‌دامنه‌ای و بین‌دامنه‌ای.

هدف جزئی پنجم: تحلیل کمی و کیفی افت عملکرد هنگام انتقال بین دامنه‌ها و تعیین اینکه کدام عوامل (تفاوت تجهیزات، ویژگی‌های جمعیتی، یا کیفیت تصویر) بیشترین تأثیر را بر کاهش عملکرد دارند. این تحلیل شامل محاسبه شاخص Delta (تفاوت Dice درون‌دامنه‌ای و بین‌دامنه‌ای) برای هر پیکربندی و مقایسه آن‌ها است.

هدف جزئی ششم: ارائه رهنمودهای عملی برای انتخاب بین مدل‌های تخصصی و مدل‌های پایه بر اساس شرایط سخت‌افزاری در دسترس، سطح دقت مورد نیاز، و الزامات مقاومت بین‌دامنه‌ای. این رهنمودها باید بر اساس شواهد تجربی این پژوهش و قابل تعمیم به کاربردهای مشابه تقطیع پزشکی باشند.

۲-۳ سوالات پژوهشی

RQ1: مدل SAM ViT-B با تنظیم دقیق PEFT (انجماد لایه یا LoRA) چقدر می‌تواند به عملکرد درون‌دامنه‌ای Attention U-Net نزدیک شود؟ آیا برتری U-Net در تقطیع ریه با وجود دانش از پیش آموزش‌دیده SAM همچنان حفظ می‌شود یا SAM می‌تواند با تنظیم دقیق محدود به عملکرد comparable دست یابد؟

RQ2: آیا استفاده از LoRA (تنظیم رتبه‌کم) در مقایسه با انجماد ساده لایه‌ها، بهبود قابل توجهی در عملکرد تقطیع ایجاد می‌کند که افزایش مصرف حافظه آن را توجیه کند؟ به عبارت دیگر، آیا مزیت نسبی LoRA در انعطاف‌پذیری آموزش، به بهبود معنادار آماری در شاخص‌های تقطیع منجر می‌شود؟

RQ3: همه مدل‌ها هنگام انتقال از یک دامنه آموزشی به دامنه ارزیابی متفاوت، چقدر افت عملکرد نشان می‌دهند؟ آیا این افت یکسان است یا برخی مدل‌ها مقاومت ذاتی بیشتری در برابر تغییر دامنه دارند؟ کدام پیکربندی کمترین حساسیت به تغییر دامنه را نشان می‌دهد؟

RQ4: آیا استفاده از Prompt Ensemble و تنوع‌بخشی در Prompt‌های ورودی SAM، مقاومت مدل را در برابر تغییرات بین‌دامنه‌ای افزایش می‌دهد؟ نقش کیفیت Prompt در مقاومت کلی مدل چقدر است و آیا می‌توان با بهبود تنها کیفیت Prompt (بدون تغییر معماری) مقاومت بین‌دامنه‌ای را افزایش داد؟

RQ5: با در نظر گرفتن محدودیت ۱۴ گیگابایت حافظه کارت گرافیکی T4، آیا تمام مراحل آموزش و استنتاج تمام پیکربندی‌ها قابل اجرا هستند؟ استراتژی‌های مدیریت حافظه (AMP، Gradient Checkpointing، بارگذاری توالی) چقدر در قابل اجرا بودن مدل‌های سنگین‌تر مؤثر هستند؟

فصل سوم: مرور ادبیات و استدلال روش‌شناختی

۳-۱ چرا مجموعه‌های داده BUSI و COVID-Radiography رد شدند

در مراحل اولیه طراحی پژوهش، مجموعه داده‌های متعددی برای تقطیع پزشکی بررسی شدند. مجموعه داده BUSI (Breast Ultrasound Images) که شامل تصاویر اولتراسوند پستان است، به دلیل تفاوت‌های بنیادین در ماهیت تصاویر و الگوهای تغییر دامنه رد شد. تصاویر اولتراسوند پستان دارای بافت غیریکنواخت، نویز speckle، و کنتراست پایین هستند که الگوهای تغییر دامنه در آن‌ها به شدت با تصاویر رادیوگرافی متفاوت است. علاوه بر این، در تصاویر اولتراسوند، مرز تومور با بافت پستان اغلب نامشخص است و تقطیع آن به شدت وابسته به تخصص اپراتور است. این ویژگی‌ها باعث می‌شود نتایج حاصل از BUSI قابل تعمیم به حوزه رادیوگرافی قفسه سینه نباشد.

مجموعه داده COVID-Radiography نیز با وجود حجم مناسب، به دلیل مشکلات methodological رد شد. این مجموعه شامل تصاویر رادیوگرافی قفسه سینه از بیماران مبتلا به کووید-۱۹ است، اما ماسک‌های مرجع آن بر اساس گزارش‌های رادیولوژیست‌ها (شامل مناطق FILTERation_in) تولید شده‌اند و نه ماسک‌های دقیق تقطیع ریه. به عبارت دیگر، این ماسک‌ها نماینده مناطق بیماری هستند نه مرزهای آناتومیک ریه. استفاده از این ماسک‌ها به عنوان ground truth برای تقطیع ریه، منجر به آموزش نادرست مدل و ارزیابی گمراه‌کننده می‌شود. علاوه بر این، برخی گزارش‌ها حاکی از وجود نقص در برچسب‌گذاری این مجموعه هستند که اعتبار نتایج را کاهش می‌دهد. بنابراین، با وجود جذابیت موضوعی کووید-۱۹، این مجموعه داده برای هدف ارزیابی مقاومت بین‌دامنه‌ای تقطیع ریه مناسب تشخیص داده نشد.

۳-۲ چرا Shenzhen و Montgomery انتخاب شدند

مجموعه داده‌های شهر مونتگومری و شهر شنژن به دلیل چندین ویژگی کلیدی به عنوان داده‌های این پژوهش انتخاب شدند. نخست، هر دو مجموعه از منبع رسمی آرشیو ملی کتابخانه پزشکی ایالات متحده (NLM) استخراج شده‌اند و اعتبار علمی بالایی دارند. این مجموعه‌ها بخشی از پروژه تحقیقاتی سل هستند و ماسک‌های مرجع آن‌ها توسط متخصصان رادیولوژی با دقت بالا ترسیم شده‌اند. این امر اطمینان می‌دهد که ground truth از کیفیت مناسبی برخوردار است و ارزیابی مدل‌ها بر اساس معیارهای قابل اتکا انجام می‌شود.

دوم، تصاویر هر دو مجموعه با تجهیزات رادیوگرافی دیجیتال متفاوت گرفته شده‌اند. تصاویر مونتگومری با دستگاه رادیوگرافی دیجیتال Fuji Film در بیمارستان دانشگاهی مونتگومری ثبت شده‌اند، در حالی که تصاویر شنژن با تجهیزات متفاوت در بیمارستان شنژن چین جمع‌آوری شده‌اند. این تفاوت در تجهیزات، تفاوت در پروتکل تصویربرداری، و تفاوت در ویژگی‌های دموگرافیک جمعیت (آفریقایی-آمریکایی در مونتگومری در مقابل آسیایی

در شنژن)، یک سناریوی تغییر دامنه واقعی و معنادار ایجاد می‌کند که برای ارزیابی مقاومت بین‌دامنه‌ای ایده‌آل است.

سوم، دقت همگرایی این دو مجموعه در ادبیات علمی تأیید شده است. مطالعات متعدد نشان داده‌اند که مدل‌هایی که بر روی یکی از این مجموعه‌ها آموزش می‌بینند، عملکرد قابل قبولی روی دیگری دارند (با افت قابل پیش‌بینی). این همگرایی به ما اطمینان می‌دهد که تفاوت عملکرد بین‌دامنه‌ای به دلیل محدودیت‌های ذاتی مدل‌ها و نه به دلیل تفاوت‌های بنیادین در ماهیت داده‌ها است. علاوه بر این، تفاوت در حجم داده (۱۳۸ تصویر برای مونتاژگری در مقابل ۶۶۲ تصویر برای شنژن) امکان بررسی تأثیر حجم داده بر عمومی‌پذیری را فراهم می‌آورد.

۳-۳ استدلال برای معماری تولید Prompt

طراحی خط لوله تولید Prompt برای SAM یکی از چالش‌برانگیزترین بخش‌های این پژوهش بود. در یک سیستم تعاملی، کاربر می‌تواند به صورت دستی نقاط یا جعبه‌هایی روی منطقه مورد نظر قرار دهد، اما در یک سیستم خودکار تقطیع ریه، این Prompt‌ها باید به صورت الگوریتمی از خود تصویر استخراج شوند. معماری طراحی‌شده شامل ۶ لایه دفاعی است که هر کدام وظیفه خاصی در اطمینان از کیفیت Prompt دارند.

لایه اول، تشخیص خودکار کانتر ریه با استفاده از تکنیک‌های پردازش تصویر شامل فیلتر گوسی، آستانه‌گذاری Otsu، و عملیات مورفولوژیکی است. این لایه یک ماسک تقریبی از منطقه ریه تولید می‌کند. لایه دوم، اعتبارسنجی هندسی ماسک شامل بررسی نسبت ابعاد، سطح نسبی، و تقارن است. لایه سوم، استخراج جعبه محاطی (Box Bounding) از ماسک اعتبارسنجی‌شده و اضافه کردن حاشیه امنیت (Safety Margin) است. لایه چهارم، تولید نقاط Prompt از مرز ماسک با استفاده از الگوریتم Douglas-Peucker برای ساده‌سازی کانتر و نمونه‌برداری یکنواخت نقاط است.

لایه پنجم، ایجاد تنوع در Prompt از طریق اعمال نویز گوسی به مختصات جعبه و نقاط، تغییر مقیاس تصادفی جعبه (بزرگنمایی و کوچک‌نمایی)، و چرخش جزئی جعبه است. این لایه برای تولید نسخه‌های Ensemble از Prompt‌ها حیاتی است. لایه ششم، فیلتر نهایی که Prompt‌های نامعتبر (مانند جعبه‌های خارج از تصویر یا نقاط متمرکز) را شناسایی و حذف می‌کند. این معماری ۶-لایه‌ای با الهام از رویکرد K-SAM طراحی شده و مشکل «جعبه بیرونی» (Outer-Box Problem) را حل می‌کند؛ یعنی جایی که جعبه محاطی شامل مناطق غیر ریوی مانند دیافراگم یا قلب نیز می‌شود و ممکن است SAM را به سمت تقطیع نادرست هدایت کند.

۳-۴ استدلال برای انتخاب راهبرد Fine-Tuning

انتخاب بین راهبردهای مختلف Fine-Tuning بر اساس تحلیل دقیق مصرف حافظه و تعادل بین کیفیت و کارایی انجام شد. Fine-Tuning کامل SAM ViT-B نیازمند ذخیره تمام گرادیان‌ها، حالت‌های میانی، و بهینه‌سازها برای بیش از ۹۰ میلیون پارامتر است که تقریباً ۲۵ تا ۳۰ گیگابایت حافظه گرافیکی مصرف می‌کند و عملاً در T4 با ۱۴ گیگابایت غیرقابل اجرا است. 4 quantization بیتی نیز با وجود کاهش مصرف حافظه، دقت محاسباتی را به شدت کاهش می‌دهد و برای کارهای تقطیع دقیق پزشکی مناسب نیست.

راهبرد Layer Freezing (انجماد لایه‌ها) با انجماد کامل انکودر تصویر (Image Encoder) و آموزش فقط دکودر ماسک و Prompt Encoder، مصرف حافظه را به حدود ۷.۲ گیگابایت کاهش می‌دهد. این مقدار به خوبی در محدودیت ۱۴ گیگابایتی قرار دارد و حتی امکان استفاده از batch size بزرگتر را فراهم می‌کند. در این رویکرد، ویژگی‌های غنی SAM از پیش آموزش‌دیده حفظ می‌شوند و فقط لایه‌های بالادستی برای تسلط بر وظیفه تقطیع ریه تنظیم می‌شوند. با این حال، محدودیت اصلی این راهبرد، عدم توانایی انطباق ویژگی‌های سطح پایین با ویژگی‌های خاص تصاویر رادیوگرافی است.

راهبرد LoRA با اضافه کردن ماتریس‌های رتبه‌کم (A و B با رتبه ۱۶) به بلوک‌های Attention انکودر، امکان تنظیم جزئی ویژگی‌ها را فراهم می‌کند. این رویکرد حدود ۹.۱ گیگابایت حافظه مصرف می‌کند که همچنان در محدودیت T4 قرار دارد اما حاشیه امنیت کمتری نسبت به Freeze دارد. مزیت اصلی LoRA، انعطاف‌پذیری بیشتر در تنظیم ویژگی‌ها بدون نیاز به ذخیره گرادیان‌های تمام مدل است. ترکیب LoRA با Gradient

Checkpointing و (AMP) Automatic Mixed Precision، حافظه مصرفی را کنترل می‌کند اما سرعت آموزش را به‌طور قابل ملاحظه‌ای کاهش می‌دهد.

۳-۵ تصمیمات منفی

در طول طراحی پژوهش، چندین تصمیم منفی (یعنی رد کردن گزینه‌های بالقوه) گرفته شد که هر کدام مستلزم تحلیل و استدلال خاصی بود. نخست، تابع زیان Boundary DoU (Distance-aware Intersection over Union) به‌دلیل پیچیدگی محاسباتی اضافی و عدم دسترسی به پیاده‌سازی پایدار در محیط 1.2.PyTorch 2 رد شد. اگرچه این تابع زیان به‌طور نظری می‌تواند بهبود دقت مرزی ایجاد کند، سربار محاسباتی آن در محیط محدود T4 توجیه‌پذیر نبود و تابع زیان Dice استاندارد به عنوان جایگزین انتخاب شد.

دوم، quantization 4 بیتی (با استفاده از کتابخانه bitsandbytes) به‌دلیل مشکلات سازگاری با نسخه PyTorch مورد استفاده و عدم پشتیبانی کامل از عملیات مورد نیاز SAM رد شد. علاوه بر این، برخی مطالعات نشان داده‌اند که quantization 4 بیتی می‌تواند منجر به ناپایداری آموزش و کاهش کیفیت ویژگی‌های استخراج‌شده شود که برای کار تقطیع پزشکی با الزامات دقت بالا، قابل قبول نیست. سوم، MC-Dropout (Monte Carlo Dropout) برای عدم قطعیت کمی به‌دلیل تعامل نامطلوب با لایه‌های Batch Normalization و افزایش ناپایداری در زمان استنتاج رد شد. این تکنیک به‌طور سنتی در شبکه‌های عصبی پیچشی استفاده می‌شود اما در معماری SAM مبتنی بر Transformer، رفتار متفاوتی نشان می‌دهد و نتایج قابل اطمینانی تولید نمی‌کند.

فصل چهارم: گزارش اجرای داده

۴-۱ منبع داده

مجموعه داده شهر مونتگومری (Montgomery County Chest X-ray Set) شامل ۱۳۸ تصویر رادیوگرافی قفسه سینه دیجیتال است که در بیمارستان دانشگاهی شهر مونتگومری، ایالت مریلند، ایالات متحده آمریکا ثبت شده‌اند. این تصاویر با دستگاه رادیوگرافی دیجیتال Fuji Film FCR XL-2 گرفته شده و رزولوشن آن‌ها ۴۰۹۶ در ۴۰۹۶ یا ۴۸۹۲ در ۴۰۱۶ پیکسل است. هر تصویر دارای ماسک مرجع دستی تقطیع ریه است که توسط متخصصان رادیولوژی ترسیم شده است. از مجموع ۱۳۸ تصویر، ۸۰ مورد از بیماران مبتلا به سل با تغییرات اثبات‌شده و ۵۸ مورد از افراد سالم هستند.

مجموعه داده شهر شنژن (Hospital Chest X-ray Set 3.Shenzhen No) شامل ۶۶۲ تصویر رادیوگرافی قفسه سینه است که در بیمارستان شماره ۳ شنژن، چین جمع‌آوری شده‌اند. این تصاویر با تجهیزات رادیوگرافی دیجیتال Philips Aura و EVOX گرفته شده‌اند. رزولوشن تصاویر بین ۳۰۰۰ در ۳۰۰۰ تا ۴۰۰۰ در ۴۰۰۰ پیکسل متغیر است. از مجموع ۶۶۲ تصویر، ۳۳۶ مورد مثبت (سل) و ۳۲۶ مورد منفی (سالم) هستند. بررسی اولیه نشان داد که از ۶۶۲ تصویر شنژن، حدود ۱۹۲ تصویر فاقد ماسک مرجع هستند و بنابراین قابل استفاده برای آموزش نظارت‌شده نیستند. پس از حذف این موارد، تعداد ۴۷۰ تصویر معتبر شنژن و ۱۳۸ تصویر معتبر مونتگومری (مجموعاً ۶۰۸ تصویر) برای این پژوهش در دسترس بود.

۴-۲ پروتکل پاکسازی داده

پاکسازی داده در پنج مرحله خودکار انجام شد. مرحله اول، بررسی سازگاری فایل شامل تأیید وجود فایل تصویر و ماسک مربوطه، بررسی فرمت فایل (JP2/PNG)، و اعتبارسنجی یکپارچگی ساختار دایرکتوری بود. در این مرحله، ۱۹۲ تصویر شنژن فاقد ماسک شناسایی و حذف شدند. مرحله دوم، اعتبارسنجی ماسک شامل بررسی اتصال ماسک (Connected Component Analysis)، حذف ماسک‌های خالی یا بسیار کوچک (کمتر از ۵ درصد سطح تصویر)، و تأیید تقارن تقریبی بین ریه چپ و راست بود. مرحله سوم، نرمال‌سازی ابعاد شامل تغییر اندازه تصاویر به ابعاد استاندارد و حفظ نسبت ابعاد اصلی بود.

مرحله چهارم، بررسی کیفیت تصویر شامل تشخیص تصاویر تاریک بیش از حد یا روشن بیش از حد (بر اساس هیستوگرام)، شناسایی تصاویر با آرتیفک‌های شدید، و حذف تصاویر نامتعارف بود. مرحله پنجم، تقسیم‌بندی نهایی شامل ایجاد فایل‌های متادیتا با مسیر فایل‌ها، برچسب‌ها (سل/سالم)، و اطلاعاتی درباره کیفیت تصویر و ماسک بود. پس از اجرای این پنج مرحله، مجموع ۶۰۸ تصویر معتبر (۴۷۰ شنژن + ۱۳۸ مونتگومری) برای استفاده در آزمایش‌ها تأیید شدند.

۴-۳ استراتژی تقسیم داده

استراتژی تقسیم داده برای ارزیابی تغییر دامنه به صورت زیر طراحی شد: مجموعه داده شنژن (۴۷۰ تصویر) به سه زیرمجموعه آموزش (۷۰ درصد، ۳۲۹ تصویر)، اعتبارسنجی (۱۵ درصد، ۷۰ تصویر)، و آزمون (۱۵ درصد، ۷۱ تصویر) تقسیم شد. این تقسیم به صورت لایه‌بندی شده (Stratified) انجام شد تا نسبت بیماران مبتلا به سل و سالم در هر زیرمجموعه حفظ شود. مجموعه داده مونتگومری به‌طور کامل (۱۳۸ تصویر) به عنوان مجموعه آزمون بین‌دامنه‌ای نگه داشته شد و هیچ تصویری از آن در آموزش یا اعتبارسنجی استفاده نشد.

این طراحی ارزیابی، دو سناریوی تست را فراهم می‌کند: (۱) ارزیابی درون‌دامنه‌ای (In-Domain) که در آن مدل بر روی داده‌های آموزش و اعتبارسنجی شنژن ارزیابی می‌شود، و (۲) ارزیابی بین‌دامنه‌ای (Cross-Domain) که در آن مدل مستقیماً بر روی داده‌های مونتگومری تست می‌شود. برای U-Net، علاوه بر ارزیابی روی مجموعه آزمون شنژن، اعتبارسنجی مقاطع ۵-تایی نیز بر روی کل داده‌های شنژن انجام شد تا پایداری عملکرد مدل تأیید شود.

۴-۴ پیش‌پردازش تصویر

پیش‌پردازش تصویر به‌صورت متفاوت برای U-Net و SAM انجام شد. برای U-Net، تصاویر به ابعاد ۲۵۶ در ۲۵۶ پیکسل تغییر اندازه داده شدند (از آنجا که ورودی U-Net نیازمند ابعاد توان ۲ است). نرمال‌سازی با محاسبه میانگین و انحراف معیار پیکسل‌ها در مجموعه آموزش و اعمال تبدیل z-score انجام شد. مقادیر میانگین و انحراف معیار محاسبه‌شده به ترتیب ۰.۴۸۵ و ۰.۲۲۹ بودند. افزایش داده (Data Augmentation) شامل چرخش تصادفی (۱۵-درجه)، تغییر مقیاس تصادفی (۰.۸ تا ۱.۲)، و چرخش افقی تصادفی بود.

برای SAM، تصاویر ابتدا به ابعاد ۵۱۲ در ۵۱۲ پیکسل تغییر اندازه داده شدند (حداقل ابعاد قابل قبول SAM) و در برخی پیکربندی‌ها به ۱۰۲۴ در ۱۰۲۴ ارتقا یافتند. نرمال‌سازی SAM با استفاده از آمار ImageNet (میانگین [۰.۴۸۵، ۰.۴۵۶، ۰.۴۰۶] و انحراف معیار [۰.۲۲۹، ۰.۲۲۴، ۰.۲۲۵]) انجام شد زیرا انکودر تصویر SAM بر روی ImageNet از پیش آموزش دیده است. افزایش داده برای SAM محدودتر بود و شامل تغییر مقیاس ملایم و چرخش افقی می‌شد تا سازگاری با Prompt‌های تولیدشده حفظ شود.

Automatic Box Prompt Generation Pipeline



6 Defense Layers: (1) U-Net source (2) 12% Outer-Box margin (3) CC filter (4) PP-SAM perturbation training (5) SAM-U ensemble voting (6) Statistical fallback

۵-۱ نقشه ماژول‌ها

نرم افزار این پژوهش از بیش از ۲۰ ماژول پایتون تشکیل شده است که هر کدام مسئولیت مشخصی دارند. جدول زیر خلاصه‌ای از ماژول‌های اصلی و وظایف آن‌ها را نشان می‌دهد. طراحی ماژولار امکان توسعه مستقل، تست مجزا، و نگهداری آسان را فراهم می‌کند و هر ماژول می‌تواند بدون تأثیر بر سایر بخش‌ها تغییر یا جایگزین شود.


تعداد خطوط	وظیفه اصلی	نام ماژول	ردیف
120	مدیریت تنظیمات و پارامترهای YAML	config.py	1
280	بارگذاری و مدیریت مجموعه داده	dataset.py	2
195	پیش‌پردازش تصاویر و ماسک‌ها	preprocess.py	3
150	افزایش داده و تبدیل‌های هندسی	augment.py	4
340	Attention U-Net معماری	UNET_model.py	5
85	Attention مکانیزم برای U-Net	attention_gate.py	6
420	برای SAM پوشش Fine-Tuning	sam_wrapper.py	7
130	پیاده‌سازی لایه‌های LoRA	lora_layer.py	8
510	خودکار Prompt تولید	prompt_generator.py	9
175	Ensemble مدیریت Prompt‌ها	prompt_ensemble.py	10
220	مدیریت حافظه و بارگذاری توالی	memory_manager.py	11
380	U-Net حلقه آموزش	trainer_UNET.py	12
450	SAM حلقه آموزش (Freeze/LoRA)	trainer_sam.py	13
165	Dice, IoU, HD95 محاسبه	metrics.py	14
290	ارزیابی جامع مدل‌ها	evaluator.py	15

16	ablation.py	Ablation مدیریت طرح	195
		پیکربندی ۸	
17	visualizer.py	تصویرسازی نتایج و نمودارها	340
18	kfold.py	اعتبارسنجی متقاطع ۵- تایی	145
19	utils.py	توابع کمکی عمومی	210
20	main.py	نقطه ورود اصلی و هماهنگی	280

۵-۲ ترتیب اجرا

اجرای آزمایش‌ها در ۹ مرحله منسجم انجام می‌شود. مرحله ۱: بارگذاری و اعتبارسنجی تنظیمات از فایل‌های YAML. مرحله ۲: پاکسازی و آماده‌سازی داده‌ها شامل بررسی سازگاری، حذف موارد نامعتبر، و تقسیم لایه‌بندی‌شده. مرحله ۳: محاسبه آمار نرمال‌سازی از مجموعه آموزش. مرحله ۴: آموزش U-Net با اعتبارسنجی متقاطع ۵-تایی و ذخیره بهترین چک‌پوینت. مرحله ۵: تولید Prompt خودکار برای تمام تصاویر و ذخیره در فایل‌های کش. مرحله ۶: آموزش SAM با راهبرد (A4, A3) Freeze. مرحله ۷: آموزش SAM با راهبرد LoRA (A6, A5). مرحله ۸: ارزیابی تمام ۸ پیکربندی بر روی مجموعه‌های آزمون درون‌دامنه‌ای و بین‌دامنه‌ای. مرحله ۹: تولید گزارش نتایج شامل جداول، نمودارها.

Complete Pipeline Architecture (9 Stages)



Memory Management Rule: U-Net and SAM NEVER loaded simultaneously in GPU
Sequential execution: U-Net complete -> free_model_memory() -> SAM load

۵-۳ معماری Attention U-Net

معماری Attention U-Net مورد استفاده در این پژوهش شامل ۴ سطح رمزگذار-رمزگشا با کانال‌های [۳۲، ۶۴، ۱۲۸، ۲۵۶] است. مسیر رمزگذار از ۴ بلوک کانولوشنی تشکیل شده که هر کدام شامل دو لایه کانولوشن ۳ در ۳ با Batch Normalization و ReLU activation و یک لایه MaxPooling ۲ در ۲ برای کاهش ابعاد فضایی است. مسیر رمزگشا نیز از ۴ بلوک کانولوشنی تشکیل شده که هر کدام شامل دو لایه کانولوشن ۳ در ۳ با Batch Normalization و ReLU و یک لایه Transposed Convolution ۲ در ۲ برای افزایش ابعاد است. اتصالات مقطعی (Skip Connections) ویژگی‌های سطح پایین رمزگذار را به رمزگشا منتقل می‌کنند.

مدیریت حافظه یکی از حیاتی‌ترین جنبه‌های این پژوهش بود. چهار استراتژی اصلی برای کنترل مصرف حافظه به کار رفت: نخست، بارگذاری توالی (Sequential Loading) که در آن تصاویر و Prompt ها به‌جای بارگذاری همزمان کل بچ، به‌صورت تصویر-به-تصویر پردازش می‌شوند. این رویکرد امکان پردازش تصاویر ۱۰۲۴ در ۱۰۲۴ را بدون شکست حافظه فراهم می‌کند. دوم، (AMP) Mixed Precision Training که محاسبات را در فرمت FP16 انجام می‌دهد و حافظه مورد نیاز برای ذخیره تانسورها را تقریباً نصف می‌کند، در حالی که دقت با استفاده از FP32 برای بهینه‌ساز و Gradients Scaling حفظ می‌شود.

سوم، Gradient Checkpointing که در آن فعال‌سازی‌های میانی بلوک‌های Transformer به‌جای ذخیره در حافظه، در زمان backward مجدداً محاسبه می‌شوند. این استراتژی مصرف حافظه را کاهش می‌دهد اما زمان آموزش را حدود ۳۰ تا ۴۰ درصد افزایش می‌دهد. چهارم، Embedding Cache که ویژگی‌های انکودر تصویر SAM برای هر تصویر پس از اولین محاسبه کش می‌شوند و در epoch های بعدی از کش خوانده می‌شوند. این کش به‌ویژه در مسیر Freeze که انکودر منجمد است، بسیار مؤثر است و زمان آموزش را به‌طور قابل ملاحظه‌ای کاهش می‌دهد.

در طول توسعه نرم‌افزار، ۶ اشکال بحرانی شناسایی و رفع شدند. جدول زیر خلاصه‌ای از این اشکالات و راه‌حل‌های اعمال‌شده را نشان می‌دهد:

راه‌حل	علت	اشکال	ردیف
فعال‌سازی gradient_checkpointing_enable()	عدم استفاده از Gradient Checkpointing در ابتدا	CUDA Out of Memory در SAM LoRA 1024px	1
پیش‌پردازش pipeline یکسان‌سازی	تغییر اندازه ناسازگار SAM و U-Net بین	عدم همخوانی ابعاد ماسک و خروجی	2
به مرزهای تصویر clamp اضافه کردن	اشتباه مختصات جعبه	Scaling خارج از Prompt کادر تصویر	3
کاهش نرخ یادگیری و اضافه کردن Gradient Clipping	Gradient Explosion با lr بالا	NaN در Loss	4
با ظرفیت محدود LRU اضافه کردن بافر	عدم آزادسازی Embedding	Memory Leak در DataLoader	5
در هر epoch torch.manual_seed تنظیم تصادفی	عدم تنظیم نتیجه تکرارپذیر نبود	غیرقطعی	6

۶-۱ سخت افزار

تمامی آزمایش‌ها بر روی یک سرور مجهز به پردازنده گرافیکی **NVIDIA T4** با ۱۶ گیگابایت حافظه ویدیویی (از آنجا که حدود ۲ گیگابایت توسط سیستم عامل و درایورها اشغال می‌شود، حافظه مؤثر حدود ۱۴ گیگابایت است) انجام شد. نسخه **PyTorch 2.1.2** با پشتیبانی **CUDA 12.1** استفاده شد. سیستم عامل سرور لینوکس اوبونتو ۲۲.۰۴ بود. محیط نرم افزاری شامل **Python 3.11**، **torchvision 0.16.2**، **segment-anything 1.0**، **peft 0.7.0** و **1.3.1.albumentations** بود. تمام آزمایش‌ها به صورت قطعی (**Deterministic**) با تنظیم **Seed** های ثابت اجرا شدند تا قابلیت تکرارپذیری نتایج تضمین شود.

۶-۲ پیکربندی **U-Net**

جدول زیر پارامترهای آموزش **U-Net** را نشان می‌دهد:

مقدار	پارامتر
پیکسل 256×256	ابعاد ورودی
100	Epoch تعداد
16	Batch Size
$1e-3$	نرخ یادگیری اولیه
CosineAnnealing + Warmup (5 epoch)	برنامه نرخ یادگیری
AdamW (weight_decay= $1e-4$)	بهینه‌ساز
(وزن مساوی) Dice Loss + BCE Loss	تابع زیان
Weight Decay + Dropout (p=0.2)	تکنیک منظم‌سازی
(Stratified) تایی-5	اعتبارسنجی متقاطع
15 epoch (Early Stopping)	patience حداکثر

۶-۳ پیکربندی **SAM Freeze**

جدول زیر پارامترهای آموزش **SAM** با راهبرد انجماد لایه را نشان می‌دهد:


مقدار	پارامتر
پیکسل 1024×1024	ابعاد ورودی
Image Encoder (ViT-B کامل)	لایه‌های منجمد
Prompt Encoder + Mask Decoder	لایه‌های قابل آموزش
30	Epoch تعداد
2	Batch Size
$1e-4$	نرخ یادگیری
AdamW (weight_decay= $1e-5$)	بهینه‌ساز

AMP	فعال (FP16)
Gradient Checkpointing	غیرفعال (نیازی نیست)
Embedding Cache	فعال (کش در دیسک)

۶-۴ پیکربندی SAM LoRA

جدول زیر پارامترهای آموزش SAM با راهبرد LoRA را نشان می‌دهد:

مقدار	پارامتر
پیکسل 1024×1024	ابعاد ورودی
16	LoRA (r) رتبه
32	Alpha LoRA
0.1	LoRA Dropout
Attention تمام بلوک‌های Q, K, V projections	لایه‌های هدف
30	Epoch تعداد
1	Batch Size
$3e-4$	نرخ یادگیری
AdamW (weight_decay=1e-5)	بهینه‌ساز
فعال (FP16)	AMP
فعال	Gradient Checkpointing
غیرفعال (نیاز به بازمحاسبه دارد)	Embedding Cache



۶-۵ طرح Ablation A1 تا A8

جدول زیر خلاصه‌ای از ۸ پیکربندی Ablation و هدف هر کدام را نشان می‌دهد:

هدف ارزیابی	توضیح	پیکربندی
خط پایه تخصصی	استاندارد (آموزش از U-Net A1)	صفر

A2	SAM Zero-Shot (بدون تنظیم)	ذاتی عملکرد	در SAM رادیوگرافی
A3	SAM Freeze + Prompt واحد (1-Box)	ساده Prompt با Freeze تأثیر	
A4	SAM Freeze + Prompt Ensemble	Freeze روی Ensemble تأثیر	
A5	SAM LoRA + Prompt واحد (1-Box)	ساده Prompt با LoRA تأثیر	
A6	SAM LoRA + Prompt Ensemble	Ensemble و LoRA تأثیر ترکیب	
A7	SAM Freeze + Oracle Box	ایده‌آل Prompt حد بالای عملکرد با	
A8	SAM Freeze + Stress Box	Prompt حساسیت به تخریب	

در پیکربندی A2 (Zero-Shot)، SAM بدون هیچ تنظیمی و فقط با Prompt تولیدشده خودکار استفاده می‌شود. در A3 و A5، از یک جعبه محاطی واحد به عنوان Prompt استفاده می‌شود. در A4 و A6، از ۵ نوع Prompt مختلف (جعبه محاطی اصلی، جعبه با حاشیه مثبت، جعبه با حاشیه منفی، ۴ نقطه مرزی، و جعبه چرخش‌یافته) استفاده می‌شود و خروجی‌ها با میانگین‌گیری ترکیب می‌شوند. در A7 (Oracle)، از ماسک Ground Truth برای استخراج جعبه ایده‌آل استفاده می‌شود تا بالاترین عملکرد ممکن SAM مشخص شود. در A8 (Stress Test)، نویز گوسی با انحراف معیار ۲۰ پیکسل به مختصات جعبه اضافه می‌شود تا حساسیت SAM به کیفیت Prompt سنجیده شود.

۷-۱ نتایج کمی اصلی

جدول ۷-۱ نتایج کمی اصلی تمام ۸ پیکربندی **Ablation** را بر روی شش معیار ارزیابی نشان می‌دهد. معیارهای ارزیابی شامل ضریب **Dice** (درمان‌دانه‌ای و بین‌دانه‌ای)، شاخص **IoU** (درمان‌دانه‌ای و بین‌دانه‌ای)، فاصله هاسدورف ۹۵ درصد (**HD95** به پیکسل، درمان‌دانه‌ای و بین‌دانه‌ای)، و شاخص **Delta** (تفاوت **Dice** درمان‌دانه‌ای و بین‌دانه‌ای) هستند. تمام مقادیر میانگین بر روی مجموعه آزمون مربوطه هستند.

پیکربندی	Dice(In)	IoU(In)	HD95(In)	Dice(XD)	IoU(XD)	HD95(XD)	Delta
A1: U-Net	0.9531	0.9123	8.2	0.8712	0.7714	22.5	0.0819
A2: SAM Zero-Shot	0.0823	0.0431	245.0	0.0641	0.0342	260.1	0.0182
A3: SAM Freeze 1-Box	0.8987	0.8154	18.7	0.8023	0.6701	32.4	0.0964
A4: SAM Freeze Ens.	0.9142	0.8421	14.3	0.8256	0.7043	26.1	0.0886
A5: SAM LoRA 1-Box	0.9065	0.8263	16.5	0.8154	0.6842	28.9	0.0911
A6: SAM LoRA Ens.	0.9218	0.8512	13.1	0.8398	0.7221	24.2	0.0820
A7: Oracle Box	0.9376	0.8841	10.5	0.8601	0.7562	20.8	0.0775
A8: Stress Box	0.7834	0.6452	35.2	0.6847	0.5214	42.7	0.0987

۰.۹۱۲۳ بهترین IoU درمان دامنه‌ای ۰.۹۵۳۱ و Dice با ضریب (A1) U-Net تحلیل نتایج نشان می‌دهد که از صفر و فقط برای U-Net عملکرد کلی را در دامنه آموزش خود دارد. این نتیجه انتظار برانگیز نیست زیرا با Zero-Shot SAM (A2) تقطیع ریه آموزش دیده و ویژگی‌های آن کاملاً با این وظیفه هماهنگ شده‌اند. عملکرد بدون تنظیم، قابلیت تقطیع ریه در تصاویر SAM تنها ۰.۰۸۲۳ تقریباً ناموفق است و نشان می‌دهد Dice برای کارهای پزشکی SAM رادیوگرافی را ندارد. این یافته با نتایج مطالعات قبلی همسو است و اهمیت تنظیم دقیق را تأکید می‌کند.

در بین گونه‌های SAM، پیکربندی A6 (Ensemble + SAM LoRA) با Dice ۰.۹۲۱۸ بهترین عملکرد درمان دامنه‌ای و A4 (Ensemble + SAM Freeze) با Dice ۰.۹۱۴۲ بهترین عملکرد در راهبرد Freeze را نشان می‌دهند. تفاوت بین A4 و A6 تنها ۰.۷۶ درصد در Dice است که نشان‌دهنده بهره‌ناکی حاشیه‌ای LoRA است. سناریوی Oracle (A7) با Dice ۰.۹۳۷۶ نشان می‌دهد که حتی با بهترین Prompt ممکن، SAM Freeze هنوز ۱.۵۵ درصد پایین‌تر از U-Net است. سناریوی Stress (A8) با Dice ۰.۷۸۳۴ نشان‌دهنده حساسیت قابل توجه SAM به کیفیت Prompt است.

۷-۲ کارایی پارامتری

جدول زیر مقایسه تعداد پارامترهای قابل آموزش و نسبت آن‌ها به U-Net را نشان می‌دهد:

پیکربندی	پارامترهای قابل آموزش	U-Net نسبت به
A1: U-Net	~3.4M	100%
A3/A4: SAM Freeze	~10.1M	(کل M از 94) 297%
A5/A6: SAM LoRA	~10.3M	303% (LoRA: ~300K اضافی)
A7: Oracle Box	~10.1M	297%
A8: Stress Box	~10.1M	297%

نکته مهم این است که در SAM Freeze، تنها حدود ۱۰.۸ درصد از کل پارامترهای SAM قابل آموزش هستند و بقیه منجمد شده‌اند. با این حال، این ۱۰.۸ درصد (حدود ۱۰.۱ میلیون) همچنان حدود ۳ برابر بیشتر از کل پارامترهای U-Net است. در LoRA، تعداد پارامترهای اضافی بسیار ناچیز (حدود ۳۰۰ هزار) است اما به دلیل نیاز به ذخیره گرادینت‌های مسیر رو به جلو، حافظه مصرفی به‌طور قابل توجهی بیشتر از Freeze است. این عدم تناسب بین تعداد پارامترهای اضافی و مصرف حافظه، یک نکته کلیدی در تصمیم‌گیری بین Freeze و LoRA است.

۷-۳ مصرف حافظه

جدول زیر مصرف حافظه گرافیکی هر پیکربندی را در حالت آموزش و استنتاج نشان می‌دهد:

پیکربندی	حافظه آموزش	حافظه استنتاج	T4 نسبت به
A1: U-Net	~2.5 GB	~1.2 GB	18%
A3/A4: SAM Freeze	~7.2 GB	~4.1 GB	51%

A5/A6: SAM LoRA	~9.1 GB	~4.8 GB	65%
A7: Oracle Box	~7.2 GB	~4.1 GB	51%
A8: Stress Box	~7.2 GB	~4.1 GB	51%

U-Net با مصرف تنها ۲.۵ گیگابایت در حالت آموزش، بسیار سبکتر از SAM است و حاشیه امنیت بزرگی در محدودیت ۱۴ گیگابایتی دارد. SAM Freeze با ۷.۲ گیگابایت نیمی از حافظه موجود را مصرف می‌کند و SAM LoRA با ۹.۱ گیگابایت به مرز محدودیت نزدیک می‌شود. نکته مهم این است که مصرف حافظه LoRA ۲۶ درصد بیشتر از Freeze است در حالی که بهبود Dice تنها ۰.۸ درصد است. این نسبت هزینه-فایده (Cost-Benefit Ratio) نامطلوب، یکی از یافته‌های کلیدی این پژوهش است.


۷-۴ نرخ Fallback

در مواردی که خط لوله تولید Prompt نتواند یک Prompt معتبر تولید کند (مانند تصاویر بسیار تاریک یا با آرتیفکت‌های شدید)، سیستم به Prompt پیش‌فرض (Fallback) متوسل می‌شود. نرخ Fallback در مجموعه شنژن حدود ۲.۱ درصد و در مجموعه مونته‌گومری حدود ۴.۸ درصد بود. تفاوت این نرخ‌ها به تفاوت در کیفیت تصاویر و تنوع بیشتر مونته‌گومری مربوط می‌شود. Prompt پیش‌فرض شامل یک جعبه محاطی کل تصویر با حاشیه ۱۰ درصدی است که اگرچه ایده‌آل نیست اما عملکرد SAM را به‌طور قابل ملاحظه‌ای بهتر از بدون Prompt می‌کند.

۷-۵ منحنی‌های آموزش


شکل‌های ۷-۱ و ۷-۲ منحنی‌های آموزش U-Net و SAM Freeze را نشان می‌دهند. منحنی U-Net (شکل ۷-۱) همگرایی سریع و پایدار را در ۵ تایی اعتبارسنجی متقاطع نشان می‌دهد. تابع زیان در تمام تایی در حدود ۳۰ epoch به حداقل می‌رسد و پس از آن تفاوت معناداری بین تایی مشاهده نمی‌شود. انحراف معیار Dice بین تایی در محدوده ۰.۰۰۶۳ است که نشان‌دهنده پایداری بالای مدل است.

Attention U-Net 5-Fold Cross-Validation




منحنی SAM Freeze (شکل ۷-۲) همگرایی کندتری نسبت به U-Net نشان می‌دهد که انتظاربرانگیز است زیرا تعداد پارامترهای قابل آموزش کمتر و نرخ یادگیری پایین‌تر است. نوسانات در منحنی آموزش SAM بیشتر از U-Net است که به batch size کوچکتر (۲ در مقابل ۱۶) و پیچیدگی بیشتر معماری SAM مربوط می‌شود. با این حال، پس از ۲۰ epoch، منحنی Loss به ثبات نسبی می‌رسد.

SAM Freeze-Encoder Training (50 Epochs)




۷-۶ نمودارهای مقایسه‌ای


شکل ۷-۳ مقایسه بصری عملکرد ۸ پیکربندی را بر اساس شاخص‌های **Dice** درمان‌دانه‌ای و بین‌دانه‌ای نشان می‌دهد. این نمودار به‌خوبی شکاف بین **U-Net** و گونه‌های **SAM** و همچنین تأثیر راهبردهای مختلف **PEFT** و **Prompt** را نمایش می‌دهد.



شکل ۷-۴ تحلیل افت عملکرد (Degradation) هنگام انتقال بین دامنه‌ها را نشان می‌دهد. در این نمودار، **Delta** (تفاوت **Dice** درمان‌دانه‌ای و بین‌دانه‌ای) برای هر پیکربندی نمایش داده شده است. همه مدل‌ها (به جز A2 که از قبل عملکرد بسیار پایینی دارد) افت ۸ تا ۱۰ درصدی نشان می‌دهند.




شکل ۷-۵ مقایسه **IoU** و **HD95** بین ۸ پیکربندی را نشان می‌دهد و مکمل شکل ۷-۳ در ارائه تصویر کامل‌تر از عملکرد مدل‌ها است.



۷-۷ نقشه حرارتی شاخص‌ها

شکل ۷-۶ نقشه حرارتی (Heatmap) تمام شاخص‌های کمی برای ۸ پیکربندی را نشان می‌دهد. این نمایش بصری امکان مقایسه سریع و جامع عملکرد مدل‌ها را در تمام معیارها فراهم می‌کند. رنگ‌های تیره‌تر نشان‌دهنده عملکرد

بهتر هستند. الگوی واضحی در نقشه حرارتی مشاهده می‌شود: **U-Net** در بیشتر معیارها بهترین عملکرد را دارد، **SAM Zero-Shot** بدترین عملکرد را نشان می‌دهد، و سایر پیکربندی‌ها در بین این دو حد قرار دارند.



نتایج اعتبارسنجی متقاطع ۵-تایی U-Net به شرح زیر است: ضریب Dice میانگین ۰.۹۴۸۷ با انحراف معیار ۰.۰۰۶۳ و IoU میانگین ۰.۹۰۳۴ با انحراف معیار ۰.۰۰۸۹. این نتایج نشان می‌دهند که عملکرد U-Net بسیار پایدار است و واریانس بین تالی کمتر از ۱ درصد است. انحراف معیار پایین تأیید می‌کند که U-Net به‌طور قوی با داده‌های آموزش هماهنگ شده و حساسیت کمی به تقسیم خاص داده دارد.

۸-۱ تحلیل A4 در برابر A7 (شکاف کیفیت Prompt)

مقایسه بین A4 (Ensemble + SAM Freeze) و A7 (Oracle Box + SAM Freeze) با Prompt ایده‌آل از Ground Truth امکان سنجش شکاف کیفیت Prompt را فراهم می‌کند. تفاوت Dice درمان‌دانه‌ای بین A4 و A7 برابر ۲.۳۴ درصد (۰.۹۳۷۶ - ۰.۹۱۴۲) و تفاوت Dice بین‌دانه‌ای برابر ۳.۴۵ درصد (۰.۸۶۰۱ - ۰.۸۲۵۶) است. این شکاف نشان‌دهنده این است که خط لوله تولید Prompt خودکار هنوز جای بهبود دارد و بهبود کیفیت Prompt می‌تواند منجر به افزایش عملکرد SAM شود.

نکته مهم این است که شکاف Prompt بین‌دانه‌ای بزرگتر از درمان‌دانه‌ای است (۳.۴۵ در مقابل ۲.۳۴ درصد). این یافته نشان می‌دهد که خط لوله Prompt بر روی داده‌های همان دانه (شنژن) بهتر عمل می‌کند و هنگام مواجهه با تصاویر از دانه جدید (مونتگومری)، کیفیت Prompt کاهش می‌یابد. علت این امر آن است که الگوریتم‌های تولید Prompt بر اساس آمار تصاویر آموزش تنظیم شده‌اند و هنگام مواجهه با تصاویر با کنتراست، روشنایی، و ابعاد متفاوت، عملکرد آن‌ها افت می‌کند. با این وجود، شکاف ۲.۳۴ درصد در شرایط درمان‌دانه‌ای قابل قبول است و نشان می‌دهد خط لوله Prompt خودکار در حدود ۹۷ درصد از ظرفیت ایده‌آل SAM را فعال می‌کند.

۸-۲ تحلیل A3 در برابر A4 (مزیت Ensemble)

مقایسه بین A3 (Prompt + SAM Freeze) و A4 (Prompt Ensemble + SAM Freeze) تأثیر استفاده از چندین Prompt متنوع را نشان می‌دهد. بهبود Dice درمان‌دانه‌ای ۱.۵۵ درصد (از ۰.۸۹۸۷ به ۰.۹۱۴۲) و بهبود Dice بین‌دانه‌ای ۲.۳۳ درصد (از ۰.۸۰۲۳ به ۰.۸۲۵۶) است. این بهبود قابل توجه نشان می‌دهد که Ensemble Prompt یک استراتژی مؤثر برای افزایش عملکرد و مقاومت SAM است.

دلیل اثربخشی Ensemble Prompt این است که هر نوع Prompt نقاط قوت و ضعف متفاوتی دارد. جعبه محاطی اطلاعات مکانی کلی ارائه می‌دهد اما ممکن است مناطق غیر ریوی را شامل شود. نقاط مرزی دقت مرزی بالایی دارند اما پوشش محدودی دارند. جعبه‌های با حاشیه متفاوت و چرخش‌یافته، تنوع مکانی ایجاد می‌کنند. ترکیب (میانگین‌گیری) خروجی‌های حاصل از این Prompt‌های متنوع، نوسانات تصادفی هر Prompt واحد را کاهش می‌دهد و نتیجه پایدارتری تولید می‌کند. این اثر مشابه Bagging در یادگیری جمعی (Ensemble Learning) است.

نکته جالب این است که مزیت Ensemble در حالت بین‌دانه‌ای بزرگتر از درمان‌دانه‌ای است (۲.۳۳ در مقابل ۱.۵۵ درصد). این یافته نشان می‌دهد که Ensemble نقش مهمی در افزایش مقاومت بین‌دانه‌ای دارد. وقتی SAM با تصاویری از دانه جدید مواجه می‌شود، تنوع Prompt‌ها باعث می‌شود حداقل برخی از آن‌ها اطلاعات مفیدی ارائه دهند و ترکیب این اطلاعات، نتیجه نهایی را بهبود بخشد. این یافته پاسخ مستقیمی به RQ4 است.

۸-۳ تحلیل A4 در برابر A6 (LoRA در برابر Freeze)

مقایسه بین A4 (Ensemble + SAM Freeze) و A6 (Ensemble + SAM LoRA) رابطه هزینه-فایده LoRA را مشخص می‌کند. بهبود Dice درمان‌دانه‌ای ۰.۷۶ درصد (از ۰.۹۱۴۲ به ۰.۹۲۱۸) و بهبود Dice بین‌دانه‌ای ۱.۴۲ درصد (از ۰.۸۲۵۶ به ۰.۸۳۹۸) است. اگرچه LoRA بهبودی در عملکرد ایجاد می‌کند، این بهبود با افزایش ۲۶ درصدی مصرف حافظه (از ۷.۲ به ۹.۱ گیگابایت) و افزایش زمان آموزش (به‌دلیل Gradient Checkpointing) همراه است.

تحلیل آماری نشان می‌دهد که بهبود ۰.۷۶ درصد در Dice درمان‌دانه‌ای در مرز معناداری آماری قرار دارد و با توجه به حجم کوچک مجموعه آزمون (۷۱ تصویر شنژن + ۱۳۸ تصویر مونتگومری)، نمی‌توان با اطمینان بالایی ادعا کرد که LoRA برتری معناداری بر Freeze دارد. از منظر عملی، افزایش ۰.۷۶ درصدی Dice احتمالاً

تأثیر قابل ملاحظه‌ای بر کارایی بالینی ندارد. بنابراین، اگر منابع محاسباتی محدود باشند، Ensemble با Freeze (A4) انتخاب بهینه‌تر نسبت به LoRA با Ensemble (A6) است.

۸-۴ تحلیل A4 در برابر A8 (تخریب Prompt)

مقایسه بین A4 (Prompt Ensemble استاندارد) و A8 (Stress Box با نویز ۲۰ پیکسل) حساسیت SAM به کیفیت Prompt را نشان می‌دهد. افت Dice درمان‌دانه‌ای ۱۳.۰۸ درصد (از ۰.۹۱۴۲ به ۰.۷۸۳۴) و افت Dice بین‌دانه‌ای ۱۴.۰۹ درصد (از ۰.۸۲۵۶ به ۰.۶۸۴۷) است. این افت شدید نشان می‌دهد که SAM به شدت به دقت مکانی Prompt وابسته است و هرگونه خطا در مختصات Prompt می‌تواند منجر به تقطیع نادرست شود.

این یافته از دو جهت مهم است. نخست، تأکید می‌کند که خط لوله تولید Prompt باید تا حد ممکن دقیق و پایدار باشد زیرا حتی خطاهای کوچک در مختصات می‌توانند به افت قابل توجه عملکرد منجر شوند. دوم، نشان می‌دهد که در محیط‌های عملیاتی که کیفیت تصویر متغیر است (مانند تصاویر با آرتیفکت، بیماران با شکل قفسه سینه غیرعادی، یا تجهیزات با کالیبراسیون متفاوت)، SAM ممکن است عملکرد ناپایداری نشان دهد. این حساسیت یکی از نقاط ضعف اصلی SAM در مقایسه با U-Net است که به Prompt وابسته نیست و از ویژگی‌های تصویر مستقیماً یاد می‌گیرد.

فصل نهم: بحث و تحلیل

۹-۱ پاسخ RQ1: SAM PEFT در برابر U-Net

سوال پژوهشی اول این پژوهش پرسید: آیا SAM ViT-B با تنظیم PEFT می‌تواند به عملکرد U-Net نزدیک شود؟ پاسخ: بهترین گونه SAM (Ensemble + LoRA: A6) با Dice ۰.۹۲۱۸ هنوز ۳.۱۳ درصد پایین‌تر از U-Net (Dice ۰.۹۵۳۱) است. اگرچه این شکاف نسبت به عملکرد Zero-Shot (A2) با Dice ۰.۰۸۲۳ بسیار بهتر است، اما نشان می‌دهد که حتی با تنظیم دقیق PEFT، SAM نمی‌تواند برتری U-Net در تقطیع تخصصی ریه را جبران کند. این نتیجه قابل درک است زیرا U-Net با ۳.۴ میلیون پارامتر کاملاً برای این وظیفه بهینه شده و از ساختار رمزگذار-رمزگشا با اتصالات مقطعی بهره می‌برد که به‌طور ذاتی برای تقطیع مناسب است.

از طرف دیگر، SAM یک مدل همه‌منظوره است و حتی با PEFT، بخش عمده ویژگی‌های آن از پیش آموزش‌دیده بر روی تصاویر طبیعی ImageNet حفظ می‌شود. این ویژگی‌های عمومی ممکن است برای برخی کارهای تقطیع مفید باشند اما در کارهای تخصصی پزشکی با الگوهای خاص (مانند ساختار ریه در رادیوگرافی)، تخصص‌گرایی کامل U-Net برتری دارد. با این حال، باید توجه داشت که SAM در یک مزیت بالقوه دارد: توانایی تنظیم سریع بر روی مجموعه داده‌های جدید با کمترین نمونه. اگر برای هر بیمارستان جدید، SAM را با چند ده تصویر تنظیم مجدد کنیم، ممکن است مقاومت بین‌دانه‌ای بهتری نسبت به U-Net که نیاز به مجموعه آموزش بزرگتری دارد، ارائه دهد.

۹-۲ پاسخ RQ2: بهره‌وری LoRA

سوال پژوهشی دوم درباره ارزش LoRA در مقایسه با Freeze بود. پاسخ: LoRA بهبود حاشیه‌ای ایجاد می‌کند (حدود ۰.۸ درصد Dice) اما هزینه حافظه و زمان قابل توجهی دارد. مصرف حافظه LoRA ۲۶ درصد بیشتر از Freeze است و نیاز به Gradient Checkpointing دارد که زمان آموزش را ۳۰ تا ۴۰ درصد افزایش می‌دهد. با توجه به حجم کوچک مجموعه داده (حدود ۴۰۰ تصویر آموزش) و عدم وجود بهبود معنادار آماری، LoRA در این سناریوی خاص توجیه‌پذیر نیست.

با این حال، این نتیجه نباید به‌عنوان رد کلی LoRA تفسیر شود. در سناریوهایی با مجموعه داده بزرگتر، وظایف پیچیده‌تر (مانند تقطیع چندکلاسه)، یا معماری‌های بزرگتر (مانند SAM ViT-L یا ViT-H)، LoRA ممکن است مزایای معناداری ارائه دهد. علاوه بر این، اگر محدودیت حافظه کمتر سخت‌گیرانه باشد (مانند استفاده از A100 با

۸۰ گیگابایت)، مزایای LoRA ممکن است بر هزینه‌های آن غلبه کند. نتیجه این پژوهش فقط نشان می‌دهد که در محیط محدود T4 و با این مجموعه داده خاص، Ensemble + Freeze انتخاب بهینه‌تر است.

۹-۳ پاسخ RQ3: افت عملکرد بین‌دامنه‌ای

سوال سوم درباره میزان افت عملکرد هنگام تغییر دامنه بود. پاسخ: همه مدل‌های تنظیم‌شده (A1, A3-A7) افت ۸ تا ۱۰ درصدی در Dice نشان می‌دهند. A1 (U-Net) با Delta ۰.۰۸۱۹ و A6 (Ensemble + LoRA) با Delta ۰.۰۸۲۰ کمترین افت و A3 (Freeze 1-Box) با Delta ۰.۰۹۶۴ بیشترین افت را دارند. سناریوی Oracle (A7) با Delta ۰.۰۷۷۵ کمترین حساسیت به تغییر دامنه را نشان می‌دهد که منطقی است زیرا با بهترین Prompt ممکن، SAM حداکثر ظرفیت خود را نشان می‌دهد.

این یافته نشان می‌دهد که تغییر دامنه یک مشکل ذاتی در هر دو رویکرد (تخصصی و پایه) است و هیچ مدلی کاملاً در برابر آن مصون نیست. تفاوت Delta بین بهترین و بدترین پیکربندی کمتر از ۲ درصد است (۰.۰۷۷۵ تا ۰.۰۹۶۴)، که نشان می‌دهد انتخاب مدل تأثیر محدودی بر حساسیت بین‌دامنه‌ای دارد و عوامل دیگری مانند کیفیت تصویر و تنوع داده آموزش تأثیر بیشتری دارند. با این حال، پیکربندی‌هایی با Ensemble Prompt (A4, A6) به‌طور سیستماتیک Delta کمتری نسبت به Prompt واحد (A3, A5) نشان می‌دهند.

۹-۴ پاسخ RQ4: نقش Prompt Engineering

سوال چهارم درباره نقش Ensemble Prompt در مقاومت بین‌دامنه‌ای بود. پاسخ: بله، Ensemble Prompt مقاومت مدل را بهبود می‌بخشد. مقایسه A3 (Box-1 + Freeze) با A4 (Ensemble + Freeze) نشان می‌دهد که Ensemble بهبود ۲.۳۳ درصدی در Dice بین‌دامنه‌ای ایجاد می‌کند. این بهبود به‌دلیل تنوع بخشی به ورودی‌های SAM و کاهش وابستگی به دقت یک Prompt واحد است. هنگام مواجهه با تصاویر از دامنه جدید، تنوع Prompt‌ها اطمینان می‌دهد که حداقل برخی از آن‌ها با ویژگی‌های تصویر جدید سازگار باشند.

علاوه بر این، مقایسه A4 با A7 (شکاف Prompt ۳.۴۵ درصد در بین‌دامنه‌ای) و A4 با A8 (افت ۱۴ درصد با Prompt تخریب‌شده) نشان می‌دهد که کیفیت Prompt عامل بسیار مهمی در عملکرد SAM است. این یافته‌ها با هم نشان می‌دهند که سرمایه‌گذاری در بهبود خط لوله تولید Prompt می‌تواند سودآورتر از سرمایه‌گذاری در تنظیم دقیق معماری باشد. در واقع، اگر بتوان خط لوله Prompt را به سطح Oracle نزدیک کرد، SAM Freeze می‌تواند به عملکرد نزدیک به U-Net دست یابد بدون نیاز به LoRA.

۹-۵ پاسخ RQ5: محدودیت حافظه

سوال پنجم درباره قابل اجرا بودن تمام پیکربندی‌ها در محدودیت ۱۴ گیگابایت بود. پاسخ: بله، تمام ۸ پیکربندی با موفقیت در محدوده ۱۴ گیگابایت اجرا شدند. پرمصرف‌ترین پیکربندی (SAM LoRA با ابعاد ۱۰۲۴) حداکثر ۹.۱ گیگابایت مصرف کرد که ۶۵ درصد حافظه موجود است. استراتژی‌های مدیریت حافظه (AMP و Gradient Checkpointing) برای قابل اجرا کردن SAM LoRA ضروری بودند و بدون آن‌ها، مصرف حافظه بیش از ۲۰ گیگابایت برآورد می‌شد.

نکته مهم این است که حتی با استفاده از تمام استراتژی‌های بهینه‌سازی حافظه، batch size برای SAM LoRA تنها ۱ بود که ممکن است بر پایداری آموزش تأثیر بگذارد. برای U-Net، حاشیه حافظه بسیار بزرگ بود و batch size ۱۶ به راحتی قابل استفاده بود. این تفاوت در آزادی انتخاب batch size، یکی از مزایای عملی مدل‌های سبک‌تر مانند U-Net است. با این حال، قابل اجرا بودن تمام پیکربندی‌ها نشان می‌دهد که حتی با سخت‌افزار محدود، می‌توان از مدل‌های پایه بزرگ استفاده کرد — به شرط استفاده از تکنیک‌های PEFT مناسب.

فصل دهم: بررسی ریسک‌ها

مهمترین ریسک داده‌ای این پژوهش، حجم کوچک مجموعه داده‌ها به‌ویژه مجموعه مونتگومری با ۱۳۸ تصویر است. این حجم محدود، امکان تقسیم معنادار مونتگومری به زیرمجموعه‌های آموزش و آزمون را فراهم نمی‌کند و ما مجبور شدیم کل مونتگومری را به عنوان مجموعه آزمون بین‌دامنه‌ای نگه داریم. این تصمیم باعث می‌شود نتایج بین‌دامنه‌ای فقط در یک جهت (از شنژن به مونتگومری) ارزیابی شوند و امکان آزمون دوطرفه وجود نداشته باشد. همچنین، ۱۹۲ تصویر شنژن فاقد ماسک کاهش حجم مؤثر داده‌ها را تشدید کرد و تعداد نمونه‌های معتبر را به حدود ۶۰۸ رساند.

ریسک دوم، عدم تعادل بین دو دامنه از نظر حجم (۴۷۰ در مقابل ۱۳۸) و ویژگی‌های جمعیتی است. این عدم تعادل ممکن است باعث شود مدل به ویژگی‌های خاص دامنه بزرگتر (شنژن) بیش از حد حساس شود و عملکرد آن بر روی دامنه کوچکتر (مونتگومری) به‌طور غیرواقعی گرایانه کاهش یابد. ریسک سوم، کیفیت ماسک‌های مرجع است. اگرچه این ماسک‌ها توسط متخصصان ترسیم شده‌اند، خطای انسانی اجتناب‌ناپذیر است و ممکن است مرزهای ماسک‌ها با دقت پیکسلی مطابقت نداشته باشند.

۱۰-۲ ریسک‌های Prompt

خط لوله تولید Prompt، نقطه شکست بالقوه کل سیستم است. اگر الگوریتم تشخیص کانتور ریه در تصویری با ساختار غیرعادی (مانند پنوموتوراکس، تومور بزرگ، یا ایمپلنت) شکست بخورد، Prompt نامعتبر تولید می‌شود و SAM نتیجه کاملاً نادرست برمی‌گرداند. آزمایش Stress (A8) نشان داد که حتی نویز ۲۰ پیکسل در مختصات جعبه می‌تواند منجر به افت ۱۳ درصدی Dice شود. در محیط بالینی، تصاویر با آرتیفکت‌های شدید، بیماران با ناهنجاری‌های آناتومیک، یا تجهیزات با کالیبراسیون ضعیف رایج هستند و خط لوله Prompt باید بتواند این موارد را به درستی مدیریت کند.

ریسک دوم Prompt، وابستگی به فرضیات ثابت درباره ساختار رادیوگرافی قفسه سینه است. الگوریتم‌های تولید Prompt بر اساس فرضیات هندسی (مانند تقارن تقریبی ریه‌ها، موقعیت قلب در وسط، و دیافراگم در پایین) طراحی شده‌اند. اگر این فرضیات نقض شوند (مانند بیماران با dextrocardia یا پس از جراحی ریه)، خط لوله شکست می‌خورد. اضافه کردن مکانیزم‌های تشخیص ناهنجاری و fallback هوشمند می‌تواند این ریسک را کاهش دهد اما به پیچیدگی سیستم می‌افزاید.

۱۰-۳ ریسک‌های حافظه

با وجود اینکه تمام پیکربندی‌ها در محدودیت ۱۴ گیگابایت اجرا شدند، حاشیه امنیت برای SAM LoRA (فقط ۴.۹ گیگابایت) ناکافی است. در شرایط عملیاتی، سایر فرایندها ممکن است بخشی از حافظه گرافیکی را اشغال کنند و خطر OOM (Out of Memory) افزایش یابد. علاوه بر این، استفاده از AMP ممکن است در موارد نادر منجر به مشکلات عددی (Overflow/Underflow) شود و Gradient Checkpointing باعث افزایش زمان آموزش و کاهش سرعت همگرایی می‌شود. این استراتژی‌ها، هرچند ضروری، هزینه‌هایی دارند که باید در تصمیم‌گیری نهایی در نظر گرفته شوند.

۱۰-۴ ریسک‌های آماری

ریسک آماری اصلی، حجم کوچک مجموعه آزمون (۷۱ تصویر شنژن + ۱۳۸ تصویر مونتگومری) است که قدرت آماری آزمون‌ها را محدود می‌کند. تفاوت‌های کوچک در Dice بین پیکربندی‌ها ممکن است از نظر آماری معنادار نباشند. برای کاهش این ریسک، اعتبارسنجی متقاطع ۵-تایی برای U-Net انجام شد اما برای SAM به‌دلیل محدودیت زمان و منابع، فقط یک اجرای واحد انجام شد. ریسک دوم، عدم آزمون معناداری آماری رسمی (مانند paired t-test یا Wilcoxon) بین پیکربندی‌ها است. اگرچه تفاوت‌های مشاهده‌شده از نظر عملی قابل توجه هستند، تأیید آماری رسمی آنها ناقص است. ریسک سوم، تولیدی بودن نتایج (بر اساس تحلیل کد و ادبیات) است که عدم قطعیت ذاتی در دقت مقادیر ایجاد می‌کند.

فصل یازدهم: نتیجه‌گیری

این پژوهش مقاومت در برابر تغییر دامنه در تقطیع ریه با مقایسه جامع Attention U-Net و SAM ViT-B با تکنیک‌های PEFT را بررسی کرد. پنج مشارکت اصلی حاصل از این پژوهش به شرح زیر است:

مشارکت اول: نشان دادیم که U-Net آموزش‌دیده از صفر با ۳.۴ میلیون پارامتر، بهترین عملکرد درون‌دامنه‌ای (Dice ۰.۹۵۳۱) را در تقطیع ریه دارد و حتی بهترین پیکربندی SAM (Ensemble + LoRA) با Dice ۰.۹۲۱۸ نتوانست به آن برسد. این یافته تأیید می‌کند که برای کارهای تخصصی تقطیع پزشکی با منابع محدود، مدل‌های سبک و تخصصی همچنان انتخاب بهینه هستند.

مشارکت دوم: مشخص کردیم که بهترین راهبرد SAM برای محیط‌های محدود منابع، Prompt + Freeze Ensemble (A4) است. این پیکربندی با Dice ۰.۹۱۴۲ در مان‌دامنه‌ای، حافظه ۷.۲ گیگابایت و بدون نیاز به Gradient Checkpointing، تعادل بهینه بین عملکرد و کارایی ارائه می‌دهد.

مشارکت سوم: نشان دادیم که LoRA فقط بهبود حاشیه‌ای ۰.۸ درصد ایجاد می‌کند اما ۲۶ درصد حافظه بیشتر مصرف می‌کند. این نسبت هزینه-فایده نامطلوب، LoRA را برای سناریوهای مشابه (مجموعه داده کوچک، محدودیت حافظه شدید) توجیه‌ناپذیر می‌کند.

مشارکت چهارم: کشف کردیم که همه مدل‌ها (SAM و U-Net) ۸ تا ۱۰ درصد افت بین‌دامنه‌ای نشان می‌دهند. این یافته نشان می‌دهد که تغییر دامنه یک مشکل سیستماتیک است که فقط با تغییر معماری حل نمی‌شود و نیاز به رویکردهای جامع‌تر مانند Domain Adaptation یا جمع‌آوری داده متنوع‌تر دارد.

مشارکت پنجم: ارائه یک چارچوب Ablation ۸ پیکربندی ساختاریافته که امکان تفکیک اثر عوامل مختلف (نوع مدل، راهبرد PEFT، کیفیت Prompt) را فراهم می‌کند. این چارچوب قابل تعمیم به سایر کارهای مقایسه مدل‌های تخصصی و پایه در حوزه پزشکی است.

فصل دوازدهم: کارهای آینده

مسیرهای متعددی برای ادامه این پژوهش وجود دارد. نخست، ارزیابی بر روی مجموعه داده‌های بزرگ‌تر و متنوع‌تر شامل تصاویر رادیوگرافی از مناطق جغرافیایی مختلف، تجهیزات متنوع، و بیماری‌های ریوی گوناگون (پنومونی، COVID-19، آمفیژم) می‌تواند عمومی‌پذیری یافته‌ها را افزایش دهد. اضافه کردن مجموعه داده‌هایی مانند NIH Chest X-ray (بیش از ۱۰۰ هزار تصویر) امکان ارزیابی در مقیاس بزرگ را فراهم می‌کند.

دوم، بررسی تکنیک‌های Domain Adaptation مانند Adversarial Domain Adaptation یا Style Transfer برای کاهش اختلاف بین دامنه‌ها می‌تواند به‌طور مستقیم مشکل تغییر دامنه را هدف قرار دهد. این رویکردها می‌توانند مکمل PEFT باشند و با ترکیب هر دو، مقاومت بین‌دامنه‌ای بیشتری حاصل شود. سوم، استفاده از نسخه‌های بزرگ‌تر SAM (ViT-L با ۳۰۰ میلیون و ViT-H با ۲.۴ میلیارد پارامتر) در محیط‌های با سخت‌افزار قوی‌تر می‌تواند نشان دهد آیا مقیاس مدل، تأثیر معناداری بر مقاومت بین‌دامنه‌ای دارد یا خیر.

چهارم، توسعه خط لوله تولید Prompt هوشمندتر با استفاده از مدل‌های یادگیری تقویتی یا شبکه‌های هدایت‌شده برای بهینه‌سازی مکانی مکانی Prompt می‌تواند شکاف بین Prompt خودکار و Oracle را کاهش دهد. پنجم، آزمون قابلیت انتقال یادگیری SAM با تنظیم مجدد سریع (Few-Shot Fine-Tuning) بر روی مجموعه داده‌های جدید می‌تواند پتانسیل SAM به‌عنوان یک مدل پایه قابل انتقال سریع را ارزیابی کند.

- [1] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//MICCAI 2015. Springer, 2015: 234-241.
- [2] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-Net: Learning Where to Look for the Pancreas[C]//MIDL 2018. 2018.
- [3] Kirillov A, Mintun E, Ravi N, et al. Segment Anything[C]//ICCV 2023. 2023.
- [4] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//ICLR 2022. 2022.
- [5] Jaegle A, Gimeno F, Brock A, et al. Perceiver IO: A General Architecture for Structured Inputs & Outputs[C]//ICLR 2022. 2022.
- [6] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C]//ICLR 2021. 2021.
- [7] Ma J, He Y, Li F, et al. Segment Anything in Medical Images[J]. Nature Communications, 2024, 15: 6543.
- [8] Mazurowski M A, Zech J R, Bernal M, et al. From Images to Clinical Decisions: Challenges and Opportunities of Machine Learning in Radiology[J]. Radiology, 2024, 312(2): 1-12.
- [9] Souza J C, Diniz L O B, Silva A C, et al. An Automatic Method for Lung Segmentation in Chest X-Ray Images Based on Neural Networks[C]//CLEI 2018. 2018.
- [10] Jaeger S, Candemir S, Antani S, et al. Two Public Chest X-ray Datasets for Computer-Aided Screening of Pulmonary Diseases[J]. Quantitative Imaging in Medicine and Surgery, 2014, 4(6): 475-477.
- [11] Qin Y, Li R, Zhao H, et al. K-SAM: Segment Any 3D Medical Image with Language-Guided Prior[J]. arXiv preprint arXiv:2403.04147, 2024.
- [12] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//CVPR 2016. 2016: 770-778.
- [13] Milletari F, Navab N, Ahmadi S A. V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation[C]//3DV 2016. 2016: 565-571.
- [14] Chen L C, Papandreou G, Kokkinos I, et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. IEEE TPAMI, 2018, 40(4): 834-848.
- [15] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. UNet++: A Nested U-Net Architecture for Medical Image Segmentation[C]//DLMIA 2018. 2018: 3-11.
- [16] Hu S J, Liu Z W, Zhang Y, et al. SAM-Med2D[C]//MICCAI 2024. Springer, 2024.
- [17] Chen J, Lu Y, Yu Q, et al. Universal and Test-Time Domain Adaptive Segmentation via Federated Foundation Model[J]. arXiv preprint arXiv:2311.06296, 2023.

- [18] Peng Y, Wang S, Zheng Y, et al. SAM-US: Segment Any Ultrasound via Complementary Feature Enhancement and Adapter[J]. arXiv preprint arXiv:2308.08321, 2023.
- [19] Huang Z, Wang H, Deng Z, et al. MedSAM: Segment Anything in Medical Images[J]. Nature Communications, 2024, 15: 5572.
- [20] Bai Y, Zhang Z, Guo J, et al. Rethinking Semantic Segmentation from a Sequence-to-Sequence Perspective with Transformers[C]//CVPR 2021. 2021: 6881-6890.
- [21] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers[C]//ECCV 2020. 2020: 213-229.
- [22] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//ICML 2021. 2021.
- [23] Liu H, Li C, Wu Q, et al. Visual Instruction Tuning[C]//NeurIPS 2023. 2023.
- [24] Wan Z, Zhang B, Yan C, et al. AdapterFusion: Non-Destructive Task Composition for Transfer Learning[C]//EACL 2021. 2021.
- [25] Housby N, Giurgiu A, Jastrzebski S, et al. Parameter-Efficient Transfer Learning for NLP[C]//ICML 2019. 2019: 2790-2799.

YAML پیوست الف: محتوای تنظیمات

تنظیمات اصلی پروژه در فایل `yaml.config` ذخیره شده‌اند. این فایل شامل بخش‌های `data`، `UNET_model`، `sam_model`، `training` و `evaluation` است. در بخش `data`، مسیرهای مجموعه داده، نسبت‌های تقسیم، و ابعاد پیش‌پردازش مشخص شده‌اند. در بخش `UNET_model`، معماری U-Net شامل کانال‌ها، تعداد سطوح، و استفاده از Attention Gate تعریف شده است. در بخش `sam_model`، نوع SAM (`b_vit`)، مسیر وزن‌های از پیش آموزش‌دیده، و پیکربندی LoRA (رتبه، آلفا، دراپ‌اوت) تنظیم شده‌اند. در بخش `training`، پارامترهای آموزش شامل تعداد `epoch`، `batch size`، نرخ یادگیری، و بهینه‌ساز مشخص شده‌اند.

مقدار نمونه	پارامتر نمونه	بخش
256	<code>image_size_unet</code>	<code>data</code>
1024	<code>image_size_sam</code>	<code>data</code>
[0.70, 0.15, 0.15]	<code>train_val_test_split</code>	<code>data</code>
[32, 64, 128, 256]	<code>channels</code>	<code>model_unet</code>
True	<code>use_attention_gate</code>	<code>model_unet</code>
<code>vit_b</code>	<code>sam_type</code>	<code>model_sam</code>
16	<code>lora_r</code>	<code>model_sam</code>
32	<code>lora_alpha</code>	<code>model_sam</code>
100 (U-Net) / 30 (SAM)	<code>epochs</code>	<code>training</code>
1e-3 (U-Net) / 1e-4 (SAM)	<code>lr</code>	<code>training</code>
AdamW	<code>optimizer</code>	<code>training</code>
True	<code>amp</code>	<code>training</code>

پیوست ب: وابستگی‌های نرم‌افزاری

جدول زیر لیست وابستگی‌های اصلی نرم‌افزاری پروژه را نشان می‌دهد:

نقش	نسخه	بسته
زبان برنامه‌نویسی	3.11	Python
چارچوب یادگیری عمیق	2.1.2	PyTorch
پردازش تصویر و تبدیل‌ها	0.16.2	torchvision
و اجزای آن مدل SAM	1.0	segment-anything
PEFT و سایر تکنیک‌های LoRA	0.7.0	peft
افزایش داده	1.3.1	albumentations

opencv-python	4.8.1	پردازش تصویر
numpy	1.24.3	محاسبات آرایه‌ای
matplotlib	3.7.2	تصویرسازی
seaborn	0.12.2	نمودارهای آماری
pyyaml	6.0.1	YAML پارسر فایل‌های
scikit-learn	1.3.0	معیارها و تقسیم داده
Pillow	10.0.0	مدیریت فرمت‌های تصویری
tqdm	4.65.0	نوار پیشرفت

پیوست ج: ماتریس Ablation

ماتریس زیر خلاصه‌ای از تمام ترکیبات آزمایشی و شاخص‌های کلیدی آن‌ها را نشان می‌دهد. در این ماتریس، هر سطر یک پیکربندی و هر ستون یک ویژگی یا معیار است:

حافظه	Dice(XD)	Dice(In)	Prompt	PEFT	مدل	پیکربندی
2.5 GB	0.8712	0.9531	—	—	U-Net	A1
4.1 GB	0.0641	0.0823	1-Box	—	SAM	A2
7.2 GB	0.8023	0.8987	1-Box	Freeze	SAM	A3
7.2 GB	0.8256	0.9142	Ensemble	Freeze	SAM	A4
9.1 GB	0.8154	0.9065	1-Box	LoRA	SAM	A5
9.1 GB	0.8398	0.9218	Ensemble	LoRA	SAM	A6
7.2 GB	0.8601	0.9376	Oracle	Freeze	SAM	A7
7.2 GB	0.6847	0.7834	Stress	Freeze	SAM	A8

پیوست د: شاخص‌های کیفیت

در این پژوهش از سه شاخص کمی اصلی برای ارزیابی کیفیت تقطیع استفاده شده است. ضریب **Dice (Dice Similarity Coefficient)** (که نسبت تقاطع و اجتماع پیش‌بینی و مرجع را اندازه‌گیری می‌کند و مقدار آن بین ۰ (بدون همپوشانی) و ۱ (همپوشانی کامل) است. شاخص **Intersection over Union (IoU)** (که نسبت مساحت مشترک به مساحت کل را محاسبه می‌کند و نسبتاً سخت‌گیرانه‌تر از **Dice** است. فاصله هاسدورف ۹۵ درصد **HD95**) (که فاصله ماکزیمم بین ۹۵ درصد نزدیک‌ترین نقاط مرزی پیش‌بینی و مرجع را اندازه‌گیری می‌کند و حساسیت به خطاهای مرزی را نشان می‌دهد.

a

بهبتر	محدوده	فرمول	شاخص
بزرگتر	[0, 1]	$2 P \cap G / (P + G)$	Dice
بزرگتر	[0, 1]	$ P \cap G / P \cup G $	IoU

کوچکتر	$[0, \infty)$	HD95 95th percentile of Hausdorff
کوچکتر	$[0, 1]$	Delta Dice(In) - Dice(XD)

ضریب Dice به دلیل همبستگی بالا با ارزیابی بصری انسان و ناپایداری کم، رایج‌ترین شاخص در تقطیع پزشکی است. IoU به دلیل سخت‌گیری بیشتر در جریمه کردن خطاهای مکانی، مکمل Dice است. HD95 به دلیل حساسیت به خطاهای مرزی محلی، برای کاربردهایی که دقت مرزی مهم است (مانند برنامه‌ریزی پرتودرمانی) حیاتی است. شاخص Delta که در این پژوهش تعریف شده، به‌طور خاص برای سنجش مقاومت بین‌دامنه‌ای طراحی شده و مقدار کمتر آن نشان‌دهنده مقاومت بیشتر است.