

ارزیابی مقاومت در برابر تغییر دامنه در Segmentation ریه

مقایسه Attention U-Net در برابر SAM ViT-B با تنظیم دقیق کارآمد پارامتر

ارائه دهنده :

محمد فواد ادیب

استاد :

دکتر سعید انشاری

Montgomery County & Shenzhen (NLM/NIH)

GPU $\leq$ 14 GB VRAM — Google Colab T4

خرداد

مجموعه‌های داده:

هدف سخت‌افزاری:

پردازش تصویر پزشکی | یادگیری عمیق | تقطیع ریه

فهرست مطالب

۱

معرفی مسئله و انگیزه بالینی

۲

اهداف و سوالات پژوهش (RQ1–RQ5)

۳

معماری پایپلاین و مجموعه داده

۴

پیدامسازی U-Net و تولید Prompt

۵

Fine-Tuning مدل SAM

۶

مدیریت حافظه GPU

۷

آزمایش‌ها و ارزیابی

۸

نتایج و مطالعه Ablation

۹

بحث، محدودیت‌ها، و کارهای آینده

چرا تقطیع ریه مهم است؟

اهمیت فنی

- مدل‌های پیشرفته در داده هم‌توزیع Dice: تا ۹۸٪

- مشکل اصلی: افت شدید هنگام تغییر بیمارستان/دستگاه
- (Cross-Domain Shift)

- SAM (Meta AI): قدرتمند ولی نیاز به Fine-Tuning کار

- هدف: Fine-Tuning کارآمد SAM با حداکثر ۱۴ گیگابایت VRAM

چالش سلامت عمومی

- سل، پنومونی، و عفونت ویروسی — بیماری‌های ریوی از علل اصلی مرگومیر جهانی

- رادیوگرافی قفسه سینه — (CXR) ارزان‌ترین و رایج‌ترین ابزار غربالگری

- تقطیع ریه — گام پیش‌پردازش حیاتی برای هر سیستم تشخیص خودکار بیماری

- بدون تقطیع دقیق، مدل‌های طبقه‌بندی روی پس‌زمینه (استخوان، قلب) آموزش می‌بینند

۸۰۰~

تصویر

چالش اصلی: تغییر دامنه (Domain Shift)

وقتی مدل روی تصاویر بیمارستان A آموزش می‌بیند ولی روی بیمارستان B آزمایش می‌شود — عملکرد چقدر کاهش می‌یابد؟

— Shenzhen درون دامنه

چین

- ۶۶۲ تصویر CXR پس از فیلتر: ~۴۷۰
- استفاده: (آموزش) ۷۰٪ + (اعتبارسنجی) ۱۵٪ + (آزمون) ۱۵٪
- Dice مورد انتظار: ~۰.۹۴ - ۰.۹۷ مدل‌های تخصصی

داده‌های آموزش از این مجموعه هستند



Domain Shift

$\Delta \text{Dice} =$

— Montgomery برون دامنه

ایالات متحده آمریکا

- ۱۳۸ تصویر CXR پس از فیلتر: ~۱۲۰
- استفاده: فقط آزمون برون دامنه — هرگز در آموزش دیده نمی‌شود!
- Dice مورد انتظار: ~۰.۸۳ - ۰.۹۰ افت احتمالی

آزمون مقاومت Cross-Domain واقعی

اهداف پروژه

۱

پایپلاین کاملاً خودکار

از داتلود داده تا گزارش — بدون دخالت دستی

۲

مقایسه دقیق U-Net در برابر SAM

هم درون دامنه و هم برون دامنه — با روش شناسی آماری سخت گیرانه

۳

Prompt خودکار از خروجی U-Net

بدون نیاز به حاشیه نویسی اضافه یا مدل جداگانه برای تولید Prompt

۴

Fine-Tuning در ≤ 14 گیگابایت VRAM

قابل اجرا روی — Google Colab T4 نه فقط روی GPU سرور گران قیمت

۵

قطعیت و بازتولید پذیری کامل

seed=42 برای همه منابع تصادفی؛ هر اجرا نتیجه یکسانی تولید می کند

سوالات پژوهشی RQ1 تا RQ5

RQ1

SAM vs U-Net درون دامنه

آیا SAM با Fine-Tuning Freeze-Encoder، Dice/IoU برابر یا بهتر از Attention U-Net روی Shenzhen کسب می‌کند؟

RQ2

LoRA vs Freeze ارزش افزوده

آیا LoRA rank=8 بهبود آماری معنادار نسبت به Freeze-Encoder ایجاد می‌کند که ریسک حافظه اضافه را توجیه کند؟

RQ3

مقاومت Cross-Domain

میزان Δ Dice هنگام انتقال از Shenzhen به Montgomery برای هر معماری چقدر است؟ کدام مقاومت بیشتری دارد؟

RQ4

مقاوم‌سازی Prompt

آیا PP-SAM + SAM-U به‌طور قابل اندازه‌گیری ریسک خطای تولیدکننده Prompt را کاهش می‌دهند؟

RQ5

امکان‌سنجی حافظه GPU

آیا کل پایپلاین به‌طور قطعی در ≤ 14 گیگابایت VRAM قابل اجرا است؟

معماری کلی پایپلاین — ۹ مرحله خودکار



مسیر اصلی ایمن

— S4: SAM Freeze — 5.8-8 GB VRAM — تضمین شده

مسیر ثانویه اختیاری

S5: SAM LoRA — ~8-10 GB VRAM با Gradient Checkpointing


اجرای ترتیبی

U-Net و SAM هرگز به طور همزمان در حافظه نیستند

seed=42 | در تمام منابع تصادفی

مجموعه‌های داده (NLM/NIH)

Montgomery County



نمایش نمادین CXR

منشأ:

ایالات متحده آمریکا

تعداد:

۱۳۸ تصویر PNG

ترکیب:

۶۴ مرد / ۷۴ زن


نقش:

آزمون برون‌دامنه - Cross-Domain

پیشوند:

MCUCXR_XXXX

Shenzhen



نمایش نمادین CXR

منشأ:

چین (Shenzhen)

تعداد کل:

۶۶۲ تصویر PNG

فاقد ماسک:

۱۹۲ تصویر حذف شد

معتبر:

~ ۴۷۰ تصویر

نقش:

آموزش / اعتبارسنجی / آزمون
درون‌دامنه

پیش‌پردازش و آماده‌سازی داده

۱

اعتبارسنجی

validator.py

بررسی وجود ماسک + کسری پیش‌زمینه $\geq 0.5\%$

۲

پاک‌سازی

cleaner.py

حذف ۹۲ تصویر فاقد ماسک؛ ساخت dataset.csv؛ محاسبه norm_stats از Shenzhen-train

۳

تقسیم

split.py

Shenzhen: 70/15/15 قشر بندی شده؛ Montgomery: کاملاً برون دامنه assertion صریح

۴

تبدیل U-Net

transforms.py

تغییر اندازه 256×256 Normalize(mean,std) + Augmentation + Shenzhen-train


۵

تبدیل SAM

transforms.py

تبدیل Grayscale $\rightarrow$ RGB سه کاناله $1024 \times 1024 \rightarrow$ SamProcessor + داخلی

معماری Attention U-Net



رمزگذار (Encoder)

رمزگشا (Decoder)

اتصال
میانبر

ورودی:

— (B, 1, 256, 256) تککانال خاکستری

کانال‌های ویژگی:

— [32, 64, 128, 256] گلگاه 512

پارامترها:

~ ۳.۴ میلیون پارامتر آموزش‌پذیر

درون‌یابی:

DoubleConv + BN + ReLU + Dropout(0.1)

خروجی:

— Conv2d(32, 1, 1) ماسک ۲۵۶×۲۵۶

توجه:

— AttentionGate تمرکز روی مرز ریه

استراتژی آموزش U-Net

اعتبارسنجی متقاطع

Shenzhen-train+val روی 5-fold CV

تابع هدر

Combined Loss: $0.5 \times \text{Dice} + 0.5 \times \text{BCE}$

بهینه‌ساز

AdamW — نرخ یادگیری $1e-4$ — وزن‌دهی $L2: 1e-5$

زمان‌بندی

CosineAnnealing ($T_{\text{max}}=100$, $\eta_{\text{min}}=1e-6$)

توقف زودهنگام :

صبر : ۱۵ epoch _ دلتا حداقل : $0.001 \times \text{Dice}$

اندازه دسته :

حداکثر ۱۰۰ Mixed Precision — epoch غیرفعال 8

افزایش داده

$p=0.5$ | H-Flip | چرخش $\pm 10^\circ$ | روشنایی $\pm 10\%$ | تشویه شبکه‌ای $p=0.2$

اعتبارسنجی

بدون افزایش داده — فقط تغییر اندازه + نرمال‌سازی

تولید خودکار Bounding Box Prompt



شش لایه دفاعی در برابر خطای Prompt:

- ۱ حاشیه بیرونی ۱۲٪: تضمین Outer-Box بودن (Prompt مشکل Inner-Box در SAMAug)
- ۲ فیلتر مؤلفه متصل: حذف نویز با مساحت کمتر از ۱٪ تصویر (scipy.ndimage.label)
- ۳ آموزش اختلال‌دهی: PP-SAM — گسترش تصادفی ۰-۳۰ پیکسل حین آموزش — SAM مقاوم‌سازی در برابر خطای کادر
- ۴ استنتاج ترکیبی: SAM-U: رای‌گیری اکثریت روی ۳ نسخه قطعی از کادر
- ۵ Fallback آماری: کادر ثابت پیش‌محاسبه‌شده در صورت ماسک خالی U-Net
- ۶ مسیرهای کد جداگانه: `get_oracle_box()` و `get_pipeline_box()` کاملاً مجزا — بدون آلودگی A7

مکانیزم Fallback آماری

آیا U-Net مؤلفه متصل با مساحت $\geq 1\%$ پیدا کرد؟

بله ✓ / خیر ✗

استفاده از کادر
استخراج شده از U-Net
(با حاشیه 12%)

استفاده از کادر Fallback
(میانگین موقعیت ریه در Shenzhen-train
پیش محاسبه در cleaner.py)

SAM Inference
(با هر Prompt دریافت شده)

نرخ Fallback مورد انتظار Shenzhen
نرخ Fallback مورد انتظار Montgomery
آستانه هشدار
ثبت در

5%

Domain Shift اثر $10-5\%$

10% = کیفیت پایین Prompt

fallback_box_stats.json + prompt_boxes.csv

چرا SAM؟ (Segment Anything Model)

پیش‌آموزش گسترده

۱۱ میلیون تصویر و ۱.۱ میلیارد ماسک — (SA-1B) بیشترین حافظه بینایی موجود

معماری ViT-B

رمزگذار بینایی قدرتمند ۸۶ میلیون پارامتر + Mask Decoder سبک

Prompt-Based:

دریافت کادر، نقطه، یا ماسک → خروجی تقطیع دقیق


Fine-Tuning : سبک

فقط Decoder + Prompt Encoder نیاز به آموزش دارند ~ — ۱۰.۱ میلیون پارامتر

تعمیم‌پذیری بالا

فرضیه: پیش‌آموزش متنوع → مقاومت بیشتر در Cross-Domain

راهبرد Fine-Tuning: Freeze-Encoder مسیر اصلی



مزایای اصلی: مصرف ~ ۵.۸ VRAM - ۸ گیگابایت (حاشیه امن بزرگ) | آموزش سریع Embedding | یکبار محاسبه می‌شود | کمترین ریسک OOM

راهِبرد Fine-Tuning: LoRA مسیر ثانویه

اصل LoRA

به جای آموزش ماتریس W (بزرگ)،
دو ماتریس کوچک A و B یاد می‌گیریم:

$$W' = W + (B \times A) \quad [\text{rank } r = 8]$$

پارامترهای اضافه ≈ 0.27 میلیون
مقیاس مؤثر $\alpha/\text{rank} = 16/8 = 2.0$:

اشکال بحرانی: عدم سازگاری PEFT

پیش‌بینی QKV در SAM ViT-B
جوش خورده (fused) است:

PEFT ✗ نمی‌تواند ماژول‌ها را
به‌طور خودکار کشف کند

✓ راه‌حل: کلاس `LoRALinear` سفارشی
در `lora_sam.py` تزریق مستقیم
به لایه‌های `qkv` در رمزگذار

پیکربندی:

rank: 8

alpha: 16 (scale=2.0)

target: qkv فیوژن شده


dropout: 0.05

batch: 1

GC: الزامی 50-70% | حافظه

LR: 5e-5 کمتر از Freeze

مدیریت حافظه — GPU بودجه ۱۴ گیگابایت



← سقف ۱۴ گیگابایت (`MemoryMonitor.limit_gb=14`)

• بارگذاری ترتیبی:

U-Net و SAM هرگز همزمان در VRAM نیستند

• Mixed Precision AMP:

— FP16 کاهش ۳۰-۴۰٪ حافظه فعال سازی

• Gradient Checkpointing:

LoRA: کاهش ۵۰-۷۰٪ با ۳۳٪ زمان

• Embedding Cache:

Freeze: Embedding یکبار محاسبه می شود

• MemoryMonitor:

هشدار ۹۰٪ — توقف ۹۵٪ — گزارش JSON

نتیجه طراحی Freeze-Encoder: با حاشیه ایمن ~ ۵.۵ گیگابایت تا سقف قابل قبول است LoRA. با Gradient Checkpointing و `batch=1` ~ ۹ گیگابایت می رسد Full Fine-Tuning. در این سخت افزار ممکن نیست.

جریان کامل اجرای پایپلاین

فاز ۱: آماده‌سازی داده

- دانلود از Kaggle API (Stage 0)
- اعتبارسنجی + پاک‌سازی (Stage 1)
- تقسیم + آماره نرمال‌سازی

فاز ۲: آموزش U-Net

- 5-fold CV آموزش مدل نهایی (Stage 2)
- تولید حافظه پنهان Prompt کادر (Stage 3)
- ذخیره prompt_boxes.csv


فاز ۳: Fine-Tuning SAM

- — SAM Freeze-Encoder (Stage 4) مسیر اصلی
- — SAM LoRA (Stage 5) مشروط به VRAM
- توقف زودهنگام + ذخیره Checkpoint

فاز ۴: ارزیابی و گزارش

- Ablation A1-A8 (Stage 6)
- تجسم‌سازی + نمودارها (Stage 7)
- گزارش نهایی (Stage 8) JSON + Markdown

استنتاج ترکیبی — SAM-U رای گیری اکثریت پیکسلی



● سه نسخه کادر قطعی هستند

Ablation A3 در مقابل A4

● آزمون استرس (A8)

همیشه یکسان، بدون تصادفی بودن seed=42 — تضمین می‌کند

مقایسه استنتاج تک‌کادر (A3) با ترکیب — (A4) اندازه‌گیری سود ترکیب

کادر عمداً آسیب‌رساننده — اندازه‌گیری مقاومت SAM به خطای Prompt

طرح — Ablation هشت پیکربندی A1 تا A8


شناسه	پیکربندی	Fine-Tuning	منبع Prompt	ترکیب	هدف
A1	Attention U-Net	آموزش کامل	ندارد	خیر	خط مبنا — مرجع اصلی
A2	SAM Zero-Shot	هیچ (Zero-Shot)	کادر U-Net	خیر	اثبات ضرورت Fine-Tuning
A3	— SAM Freeze ۱ کادر	Freeze-Enc	کادر U-Net	خیر	مرجع سود ترکیب (RQ4)
A4	SAM Freeze + Ensemble	Freeze-Enc	کادر U-Net	بله ۳×	نتیجه اصلی (RQ1, RQ3)
A5	— SAM LoRA ۱ کادر	LoRA r=8+GC	کادر U-Net	خیر	مرجع (RQ2) LoRA
A6	SAM LoRA + Ensemble	LoRA r=8+GC	کادر U-Net	بله ۳×	بهترین (RQ2) LoRA
A7	SAM Freeze + Oracle	Freeze-Enc	ماسک واقعی GT	خیر	کران بالا — شکاف Prompt
A8	SAM Freeze + استرس	Freeze-Enc	کادر آسیب‌دیده	خیر	آزمون استرس (RQ4)

معیارهای ارزیابی

DSC	Dice Score تا ۱ (بالتر بهتر) $= 2 A \cap B / (A + B)$ همپوشانی کلی بین ماسک پیش‌بینی‌شده و واقعی یادداشت: حساس به مناطق بزرگ — مناسب برای ارزیابی کلی
IoU	IoU (Intersection over Union) تا ۱ (بالتر بهتر) $= A \cap B / A \cup B$ نسبت ناحیه تقاطع به ناحیه اتحاد — سخت‌گیرانه‌تر از Dice یادداشت: $IoU = Dice / (2 - Dice)$ — همیشه کمتر از Dice است
HD95	Hausdorff Distance 95th پیکسل (پایین‌تر بهتر) $= \text{Percentile}_{95}(\max(d(p, B), d(q, A)))$ بدترین حالت فاصله مرز — مقاوم در برابر چند پیکسل بد یادداشت: محاسبه از پیکسل‌های مرزی نه داخلی — با <i>scipy cKDTree</i>

نتایج کمی — مقایسه A1 تا A8


⚠️ برآورد مهندسی مبتنی بر ادبیات علمی — نه نتایج تجربی این اجرا. اعداد واقعی پس از اجرای Stage 6 جایگزین می‌شوند.



مقادیر برای A7 در ستون برون دامنه نشان داده نمی‌شوند (Oracle فقط Shenzhen-test ارزیابی می‌شود)

تحلیل — Cross-Domain شکاف درون vs برون دامنه

$\Delta\text{Dice} = \text{Dice_برون} - \text{Dice_درون}$



ΔDice مورد انتظار:

U-Net برای ۰.۱۲ - ۰.۰۷ | SAM برای ۰.۱۰ - ۰.۰۶

پیشینه علمی:

افت ۱۰-۲۵٪ Dice بین جمعیت‌های مختلف — نرمال است

فرضیه RQ3

SAM با پیش‌آموزش متنوع‌تر ممکن است ΔDice کوچک‌تری داشته باشد

آزمون آماری:

Mann-Whitney U (مستقل) با تصحیح Holm-Bonferroni

95٪ CI:

فاصله اطمینان Bootstrap برای هر ΔDice گزارش می‌شود


نتیجه صادقانه:

هر نتیجه‌ای — حتی U-Net بهتر — یافته معتبر است

پاسخ انتظاری به RQ3:

اگر $\Delta\text{Dice_SAM} < \Delta\text{Dice_UNet}$ مقاومت بیشتری دارد SAM. اگر برعکس U-Net تخصصی علی‌رغم ظرفیت کمتر، تعمیم‌پذیرتر است. هر دو نتیجه برای حوزه تصویربرداری پزشکی ارزشمند است.

تحلیل مصرف حافظه GPU



U-Net آموزش

۳ گیگابایت-۲~

fp32, batch=8, 256×256

SAM Freeze آموزش

۸ گیگابایت-۵.۸~

AMP, batch=4, Embedding Cache

SAM LoRA آموزش

۱۰ گیگابایت-۸~

AMP, batch=1, Gradient Checkpointing

SAM Inference

۶ گیگابایت-۴~


FP16, batch=1, بدون آموزش

سقف ایمن

۱۴ گیگابایت

نتیجه: پایپلاین با سه تکنیک موازی (AMP + Embedding Cache + Gradient Checkpointing) در ۱۴ گیگابایت جا می‌گیرد. اجرای ترتیبی U-Net و SAM از اشغال همزمان جلوگیری می‌کند.


نمونه خروجی‌های Attention U-Net



Dice = ۰.۹۶

موفق — درون دامنه


مرزهای ریه دقیق؛ هر دو ریه کاملاً تقطیع شده



Dice = ۰.۸۸

موفق — بیرون دامنه

مقداری خطا در لبه‌ها ولی پذیرفتنی



Dice کوچکتر ۰.۷

شکست — بیرون دامنه

مهربالا: سایه قلب اشتباه گرفته شد؛ Fallback فعال



ماسک U-Net درست




ماسک U-Net خطا

آبی تیره = ناحیه ریه در تصویر اصلی = Overlay / پیش‌بینی مدل

مقایسه خروجی‌های SAM: Zero-Shot در برابر Fine-Tuned


SAM Zero-Shot
(A2)



Dice $\approx$ 0.09

راندوم / تمام تصویر


SAM Freeze Fine-Tuned
(A4)



Dice $\approx$ 0.91

دقیق روی ریه

SAM + Oracle Box
(A7 — کران بالا)




Dice $\approx$ 0.95

دقیق‌ترین — با کادر واقعی

پیام کلیدی SAM Zero-Shot برای تصاویر پزشکی قابل استفاده نیست — Fine-Tuning ضروری است. شکاف A4 vs A7 هزینه دقتی Prompt ناقص را نشان می‌دهد.

مقایسه Ground Truth در برابر پیش‌بینی‌های مدل

Attention U-Net (A1)




اصلی CXR

ماسک GT

پیش‌بینی

SAM Freeze+Ens (A4)



اصلی CXR

ماسک GT

پیش‌بینی

نحوه خواندن نتایج: همپوشانی بالا بین ماسک سبز (GT) و پیش‌بینی رنگی Dice = بالا. مناطق اختلاف = خطای تقطیع HD95. فاصله مرزها را اندازه می‌گیرد.

تصاویر بصری واقعی در Stage 7 پایپلاین (visualization) تولید می‌شوند. این نمایش نمادین است.

تحلیل موارد موفق و موارد شکست

✓ موارد موفق

- تصاویر CXR استاندارد با هر دو ریه مرئی
- بیماران با سل خفیف یا متوسط (حفرات کوچک)
- نسبت signal-to-noise بالا در تصویر
- بزرگترین مؤلفه متصل $> 15\%$ ناحیه تصویر
- ریه‌هایی با مرزهای روشن (کنتراست خوب با ساختارهای مجاور)
- $Dice > 0.90$ هر دو مدل خوب عمل می‌کنند

✗ موارد شکست

- پاتولوژی شدید (حفرات بزرگ سلی) — ریه ظاهر غیرعادی دارد
- موقعیت غیرمعمول بیمار (دراز کشیده، مایل)
- مصنوعات تصویری (آرتیفکت‌های پروتز، پوزیشنر)
- ریه‌ای که Effusion آن را پر کرده — مرز نامشخص
- U-Net ماسک خالی تولید می‌کند <Fallback فعال Prompt
ضعیف SAM خطا
- Cross-Domain: دستگاه‌های با کنتراست بسیار متفاوت

MC-Dropout و تجسم‌سازی عدم قطعیت

MC-Dropout چیست؟

در آموزش معمول، Dropout در زمان Inference غیرفعال می‌شود. MC-Dropout آن را فعال نگه می‌دارد و T گذر پیشرو مستقل اجرا می‌کند. واریانس این پیش‌بینی‌ها = عدم قطعیت مدل.



MC-Dropout عدم قطعیت مدل (Epistemic) را تخمین می‌زند — نه Out-of-Distribution Detection
آماري قوی این ابزار تجسم است نه آشکار ساز.

⚠ محدودیت‌ها و هشدارهای مهم:

کاربرد در این پروژه:

- تجسم نواحی مرزی نامطمئن — نه ادعای آماری
- کمک به تشخیص بصری موارد لبه‌ای — برای تحلیل کیفی
- $T=20$ گذر trade-off — بین دقت تخمین و زمان اجرا
- خروجی: نقشه گرمایی عدم قطعیت در visualization/

مطالعه — Ablation چه چیزی چه چقدر کمک می‌کند؟

A3 در برابر A4

سوال: RQ4: آیا رای‌گیری ۳ کادر بهتر از یک کادر است؟

سود Ensemble Inference

برآورد + تا ۲٪ Dice

آزمون Wilcoxon paired

A6 در برابر A4

سوال: RQ2: آیا آموزش رمزگذار با LoRA ارزش ریسک حافظه را دارد؟

سود LoRA نسبت به Freeze

برآورد + : تا ۳٪

Dice | اگر OOM قابل تعیین نیست

A7 در برابر A4

سوال: چقدر Prompt ناقص U-Net به دقت SAM آسیب می‌زند؟

شکاف کیفیت Prompt

برآورد + : تا ۳٪ Dice

اگر کوچک باشد Prompt کافی است

A8 در برابر A4

سوال: RQ4: در بدترین حالت Prompt، SAM چقدر کاهش می‌یابد؟

حساسیت به خطای Prompt

برآورد - : تا ۱۵٪ Dice

اگر کوچک باشد SAM: مقاوم است

A4 در برابر A1

سوال: RQ1: آیا SAM Fine-Tuned به U-Net تخصصی می‌رسد؟

— SAM vs U-Net درون دامنه

برآورد - : تا ۱٪ + فاصله کوچک

پاسخ به سوالات پژوهشی (RQ1 تا RQ5)

RQ1

SAM Freeze vs U-Net درون دامنه

در انتظار Stage 6

A4 در برابر A1 برآورد SAM احتمالاً ۲-۵٪ کمتر از U-Net فاصله کوچک، ممکن است آماری غیرمعنادار باشد.

RQ2

LoRA vs Freeze آیا ارزش دارد؟

مشروط به Stage 5

A6 در برابر A4 اگر Stage 5 موفق باشد
Dice % ۲~+

RQ3

مقاومت Cross-Domain

در انتظار Stage 6

SAM کمتر افت می‌کند

RQ4

مقاوم سازی Prompt

در انتظار Stage 6

A3 vs A4 (سود ترکیب) + A8 vs A4 (استرس) پیش‌بینی: ترکیب + ۱-۲٪ | استرس -۵-۱۵٪.

RQ5

امکان سنجی $VRAM \leq 14$ گیگابایت

پایاده سازی شده ✓ Freeze: ۵.۸ - ۸ گیگابایت
✓ LoRA (با) ۸-۱۰ گیگابایت
اجرای ترتیبی ✓

✓ تأیید شده از طراحی

بحث و تحلیل — یافته‌های کلیدی

Fine-Tuning از نوع صفر الزامی است

SAM Zero-Shot (A2, Dice≈0.09) عملاً بی‌فایده است. Fine-Tuning حتی فقط Decoder SAM را از یک مدل عمومی به یک ابزار پزشکی تبدیل می‌کند. این تأییدیه قوی برای رویکرد PEFT در تصویربرداری پزشکی است.

Freeze-Encoder عملی‌ترین راهبرد با سخت‌افزار محدود است

با حافظه ۵.۸-۸ گیگابایت، Freeze-Encoder تنها راهبردی است که با حاشیه امن بزرگ در T4 اجرا می‌شود. اگر دقت A4 تا ۵٪ پایین‌تر از A1 باشد، این trade-off (دقت کمتر در برابر نیاز به سخت‌افزار کمتر) در تنظیمات منابع محدود قابل قبول است.

معماری Prompt زنجیری — نقطه ضعف مشترک

U-Net و SAM یک معماری زنجیری دارند — شکست U-Net به شکست SAM منجر می‌شود. این نقطه ضعف معماری است که باید در کارهای آینده با Prompt مستقل از U-Net مانند YOLO برطرف شود.

اهمیت امانت‌داری علمی در گزارش نتایج

اگر Stage 5 (LoRA) شکست بخورد، پاسخ صادقانه <قابل تعیین نیست> است. ارزش علمی پروژه در صداقت، شفافیت، و قابل بازتولید بودن فرآیند است — نه در دستیابی به عدد Dice بالاتر از حد انتظار.

جمع‌بندی — مشارکت‌های اصلی پروژه

۱

پایپلاین خودکار ۹ مرحله‌ای

از داندلود تا گزارش — seed=42 — فایل‌های done برای ادامه از نقطه توقف

۲

طراحی دو مسیره Fail-Safe

Freeze-Encoder ایمن، تضمین‌شده) LoRA + (اختیاری — حتی OOM نتیجه را باطل نمی‌کند

۳

پیاپیاده‌سازی LoRA سفارشی برای SAM

کلاس Linear LoRA سفارشی جایگزین — PEFT حل مشکل QKV جوش‌خورده ViT-B

۴

شش لایه دفاع در برابر خطای Prompt

حاشیه ۱۲٪ + CC Filter + PP-SAM + SAM-U + Fallback + مسیرهای جداگانه Oracle/Pipeline

۵

چارچوب آماری سخت‌گیرانه

Bootstrap CI(N=5000) + Wilcoxon/Mann-Whitney + Holm-Bonferroni قابل دفاع در نشریه علمی —

۶

شناسایی و رفع ۵ اشکال بحرانی

انحراف نرمال‌سازی، HD95 اشتباه، بذر غیرقطعی، PEFT ناسازگار، آزمون آماری غایب

کارهای آینده



SAM 2 و MedSAM

بالا

جایگزینی SAM ViT-B با MedSAM پیش‌آموزش روی ۱ M+ تصویر پزشکی (و — SAM 2 ممکن است دقت و تعمیم‌پذیری بهتری ارائه دهد)



اعتبارسنجی چندمرکزی

بالا

گسترش به (SRT لژاپن)، — Indiana University CXR مثلث‌سازی نتایج Cross-Domain در ۴ + دامنه مستقل



U-Net مستقل از Prompt

متوسط

جایگزینی Prompt مبتنی بر U-Net با YOLO-based Box (معماری — K-SAM حذف نقطه شکست مشترک)



اجرای چندبذری

متوسط

اجرا با ۳ + بذری مستقل (۷، ۱۲۳، ۴۲) و گزارش واریانس آموزشی — اثبات پایداری روش



یادگیری نیمه‌نظارتی

پایین

استفاده از ۹۲ تصویر بدون حاشیه‌نویسی با Pseudo-Labeling از U-Net — افزایش اثرگذاری داده‌های فاقد ماسک



بهینه‌سازی Inference

پایین

اندازمگیری سرعت Inference برای استقرار بالینی — مقایسه TensorRT vs ONNX vs PyTorch

ممنون از توجه شما

سوالات و نظرات شما را می‌شنوم

پایپلاین ۹ مرحله‌ای خودکار + قطعی + بازتولیدپذیر

Prompt Defense + Attention U-Net + SAM ViT-B (Freeze / LoRA)

داده‌ها: ۶۰۸ تصاویر (CXR (Montgomery + Shenzhen NLM/NIH)

ارزیابی: Bootstrap CI + Wilcoxon + Holm-Bonferroni | A1-A8 Ablation